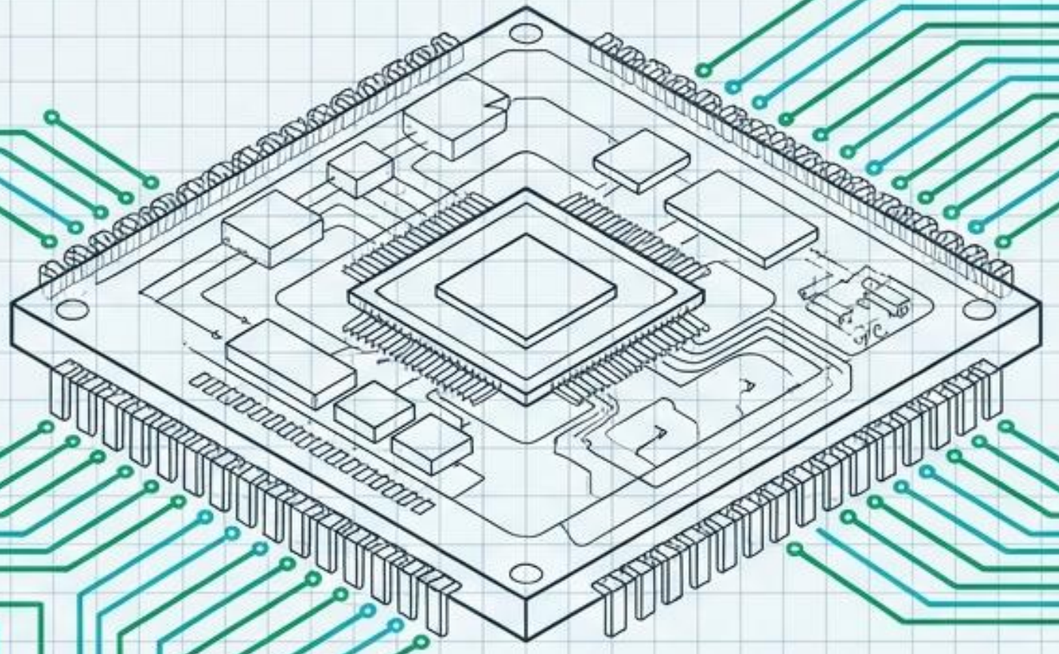
Unidade 5: Organização e Hierarquia de Memória

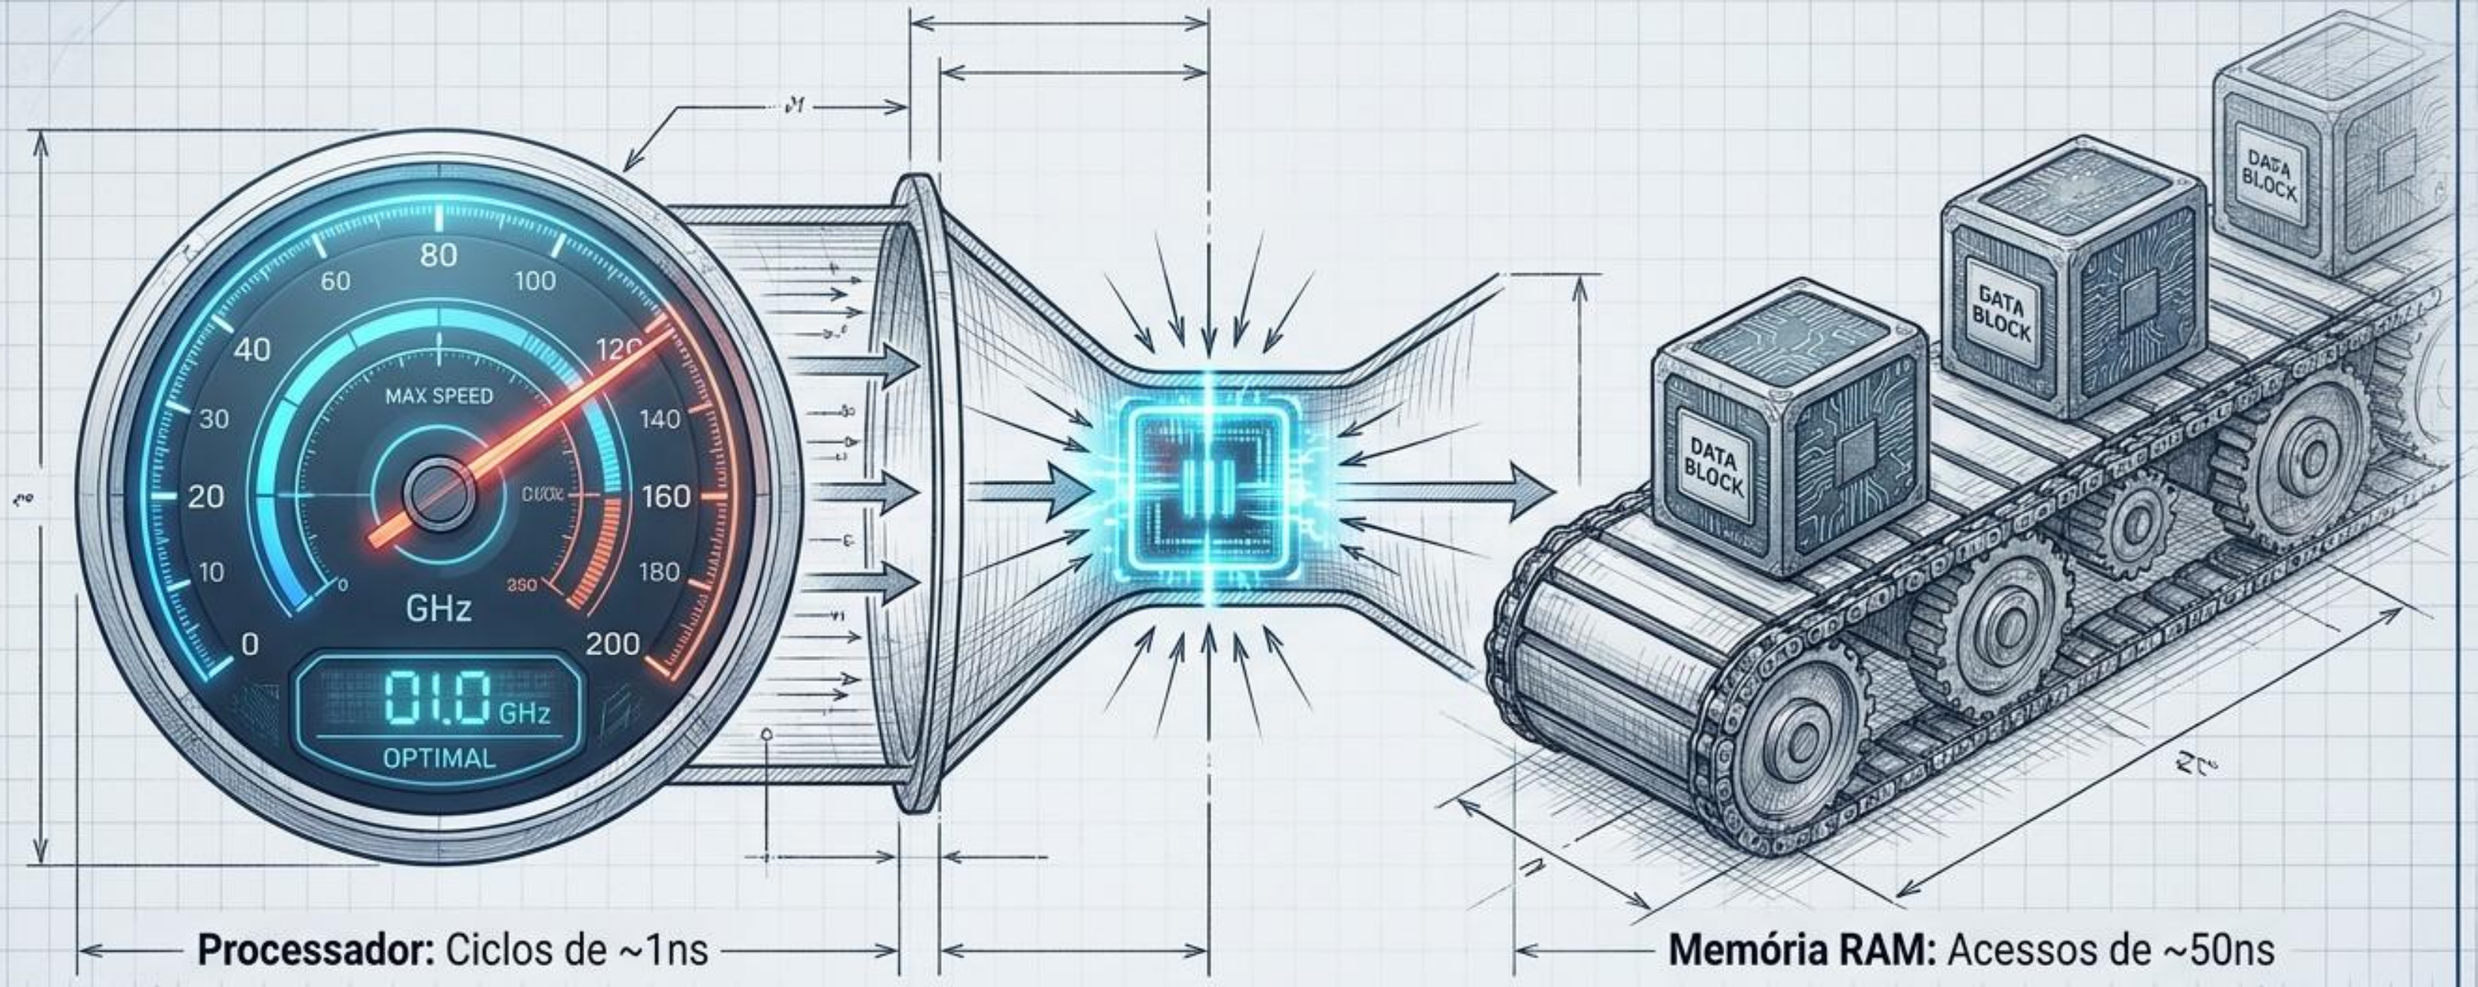
O desempenho além da CPU: Como os dados chegam ao processador



Prof. Me. Juvenal Silva Neto
Disciplina: Arquitetura e Organização de Computadores
Curso: Bacharelado em Ciência da Computação
Universidade do Estado de Mato Grosso – UNEMAT

Gemini Notebook

O Gargalo de Von Neumann: Por que uma CPU rápida fica parada?



Processador: Ciclos de ~1ns

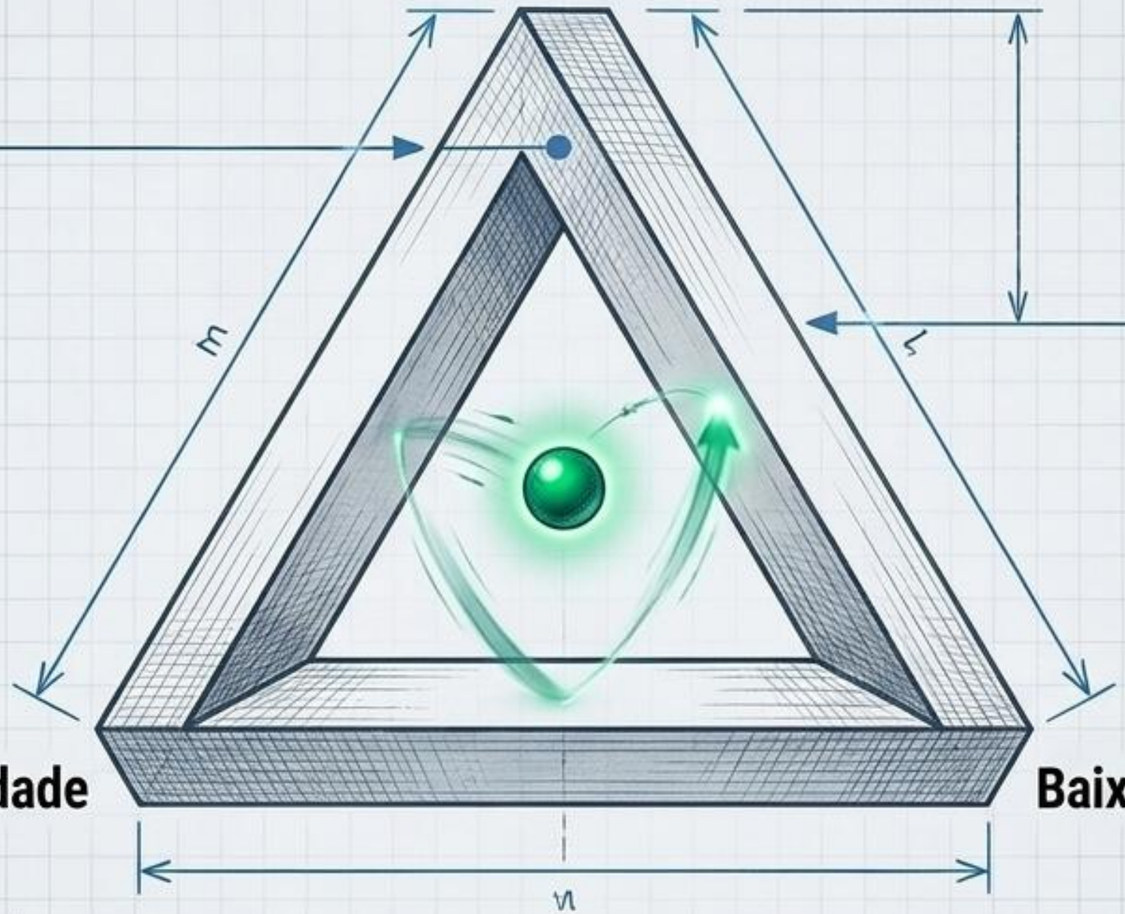
Memória RAM: Acessos de ~50ns

A Realidade: Processadores modernos passam a maior parte do tempo ociosos (Wait States), esperando os dados.
O Descompasso: A velocidade da CPU cresceu exponencialmente; a latência da memória não acompanhou.
O Axioma: Desempenho = Velocidade da CPU + Eficiência da Memória.

Gemini Notebook

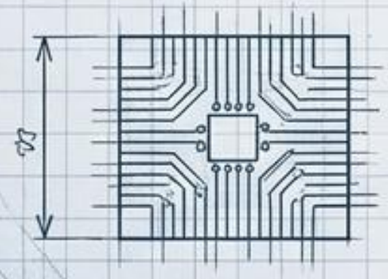
O Dilema da Engenharia: O Triângulo Impossível

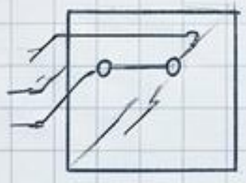
A Pergunta Central:
Por que não construímos toda a memória com a tecnologia mais rápida (SRAM)?

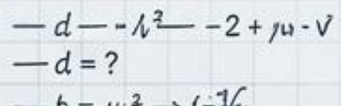


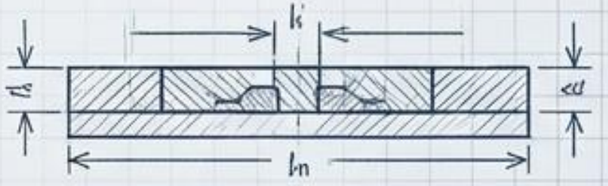
O Paradoxo Físico:
Memórias ultrarrápidas possuem baixa densidade e são absurdamente caras.

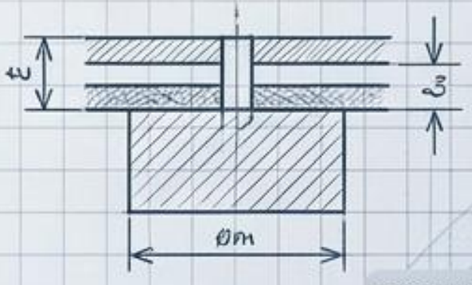
A Solução:
Abandonar a 'memória perfeita' e criar um ecossistema colaborativo.









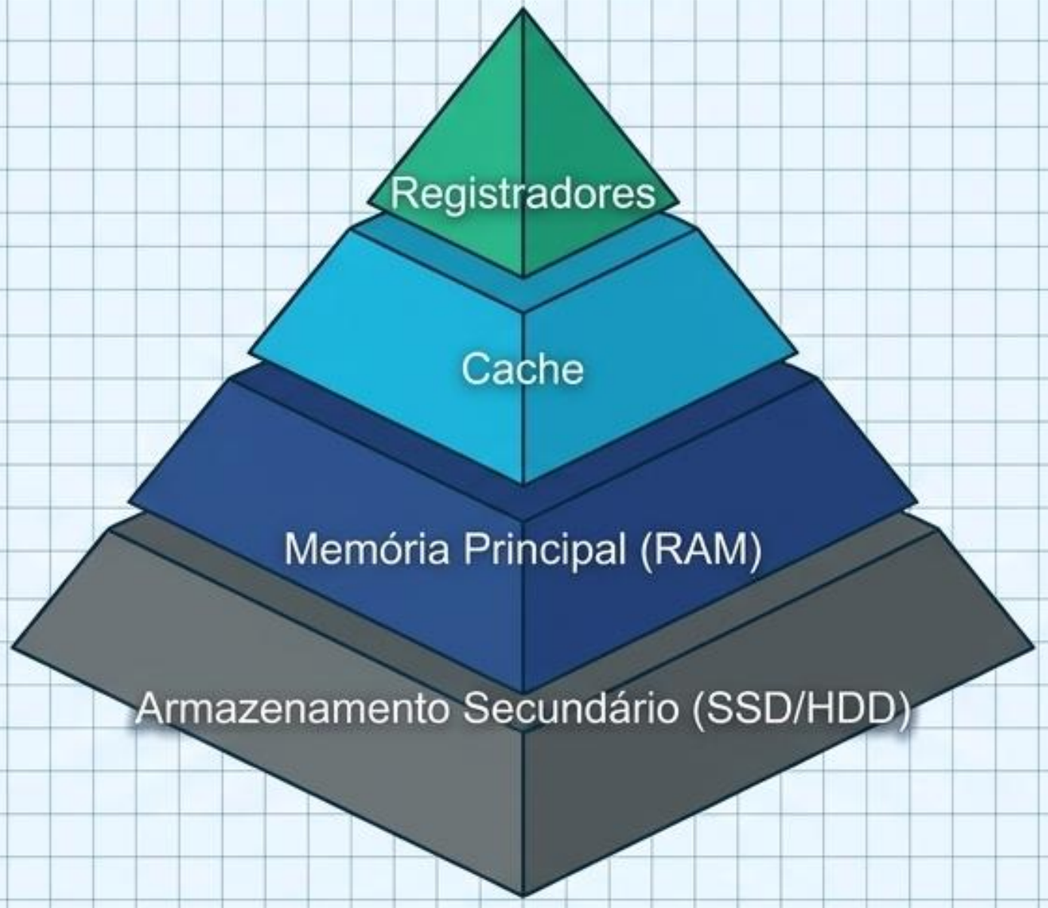


Gemini Notebook

A Ilusão Perfeita: A Hierarquia de Memória

images_1.png

Maior
Velocidade e
Custo por Bit



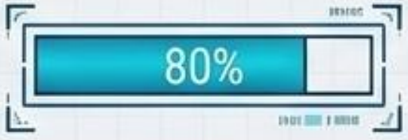
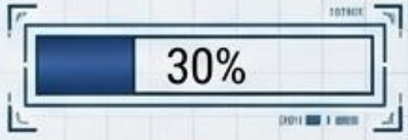
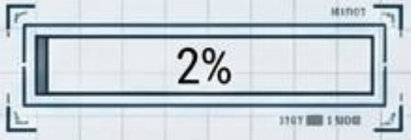
Maior
Capacidade e
Latência

images_2.png

O Objetivo: Fornecer à CPU a velocidade do topo da pirâmide com a capacidade da base.
Os dados do nível N são sempre um subconjunto do nível N+1.

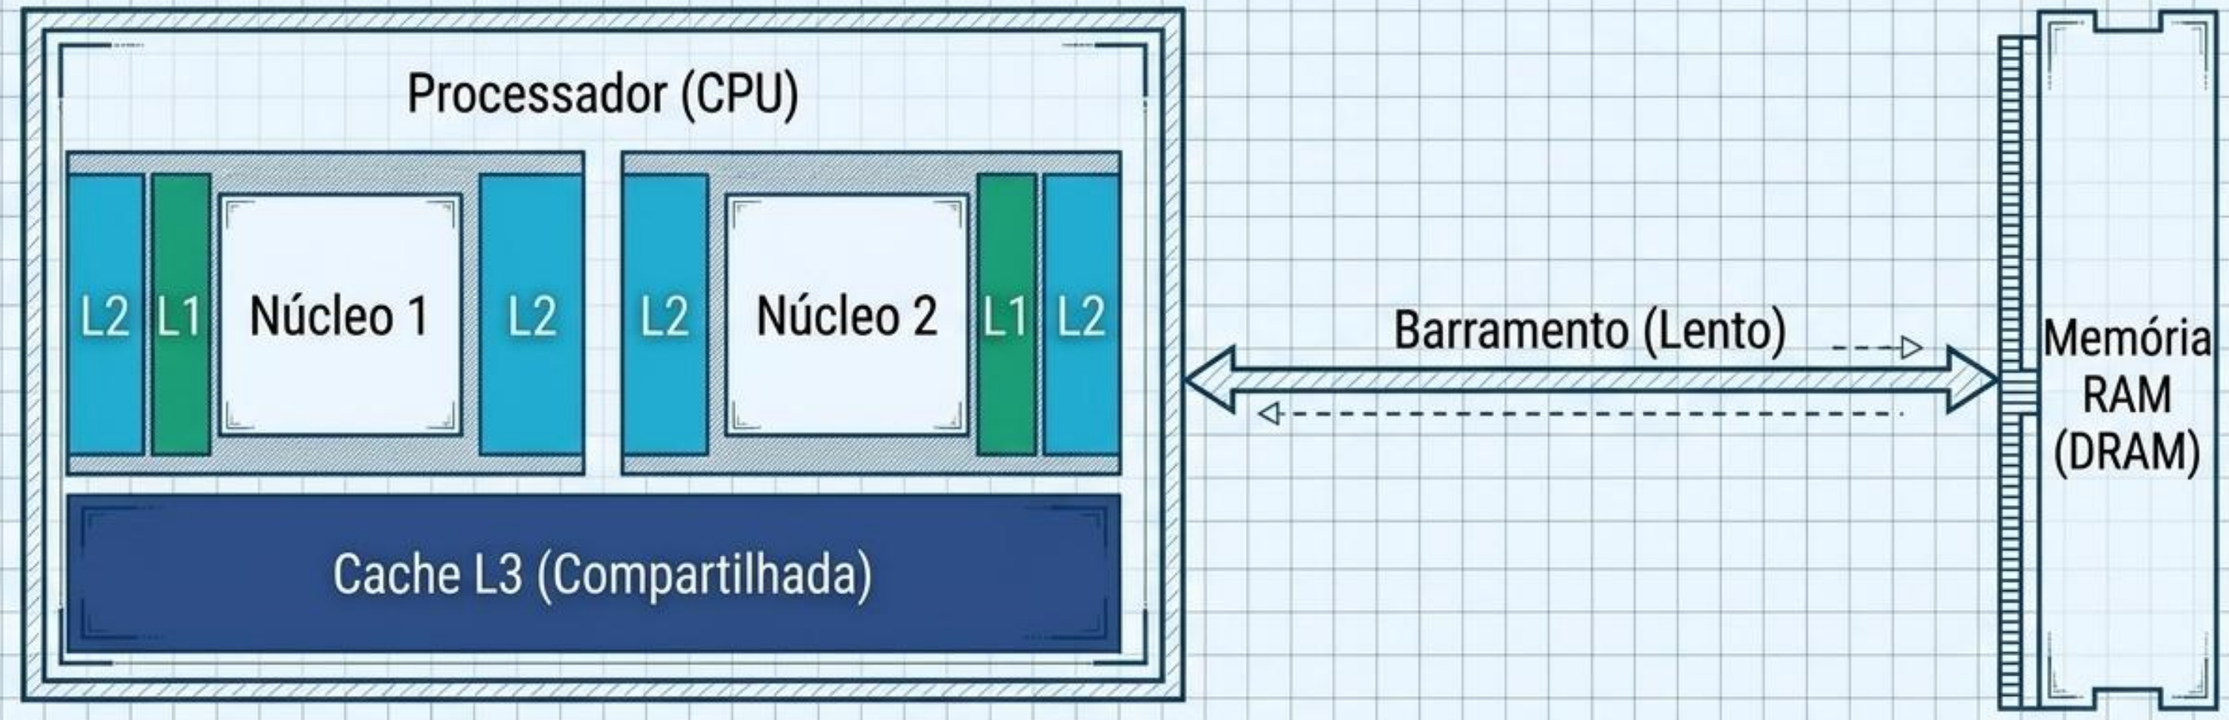
Gemini Notebook

Dissecando o Hardware: Matriz de Tecnologias

Atributo	Registradores	Cache (SRAM)	Principal (RAM)	Secundária (HD/SSD)
Localização	Dentro da CPU	Dentro da CPU	Placa-mãe	Periférico
Capacidade Típica	Bytes	Megabytes	Gigabytes	Terabytes
Latência				
Volatilidade	Volátil	Volátil	Volátil	Não-Volátil
Custo por Bit	Altíssimo	Alto	Médio	Baixíssimo

Gemini Notebook

A Estrela do Sistema: A Memória Cache (SRAM)



L1: Minúscula, privativa do núcleo, instantânea.
L2: Média, privativa, muito rápida.
L3: Maior, compartilhada no chip, ponte para a RAM.
O Papel: A Cache atua como um buffer estático (SRAM) espremido entre a CPU e a RAM, guardando os dados mais prováveis de uso.

Gemini Notebook

O Segredo da Previsão: Princípio da Localidade

A Metáfora Analógica

A Mesa de Estudos

Localidade Espacial: Trazer o livro vizinho para a mesa.



Localidade Temporal: Manter o livro aberto porque você relerá a página.

A Máquina Digital

O Código na Memória

```
int main() {
   int vetor[1000];
   for (int i = 0; i < 1000; i++) {
      vetor[i] = i * 2; // Acesso contíguo
   }
   // ... mais código ...
}
```

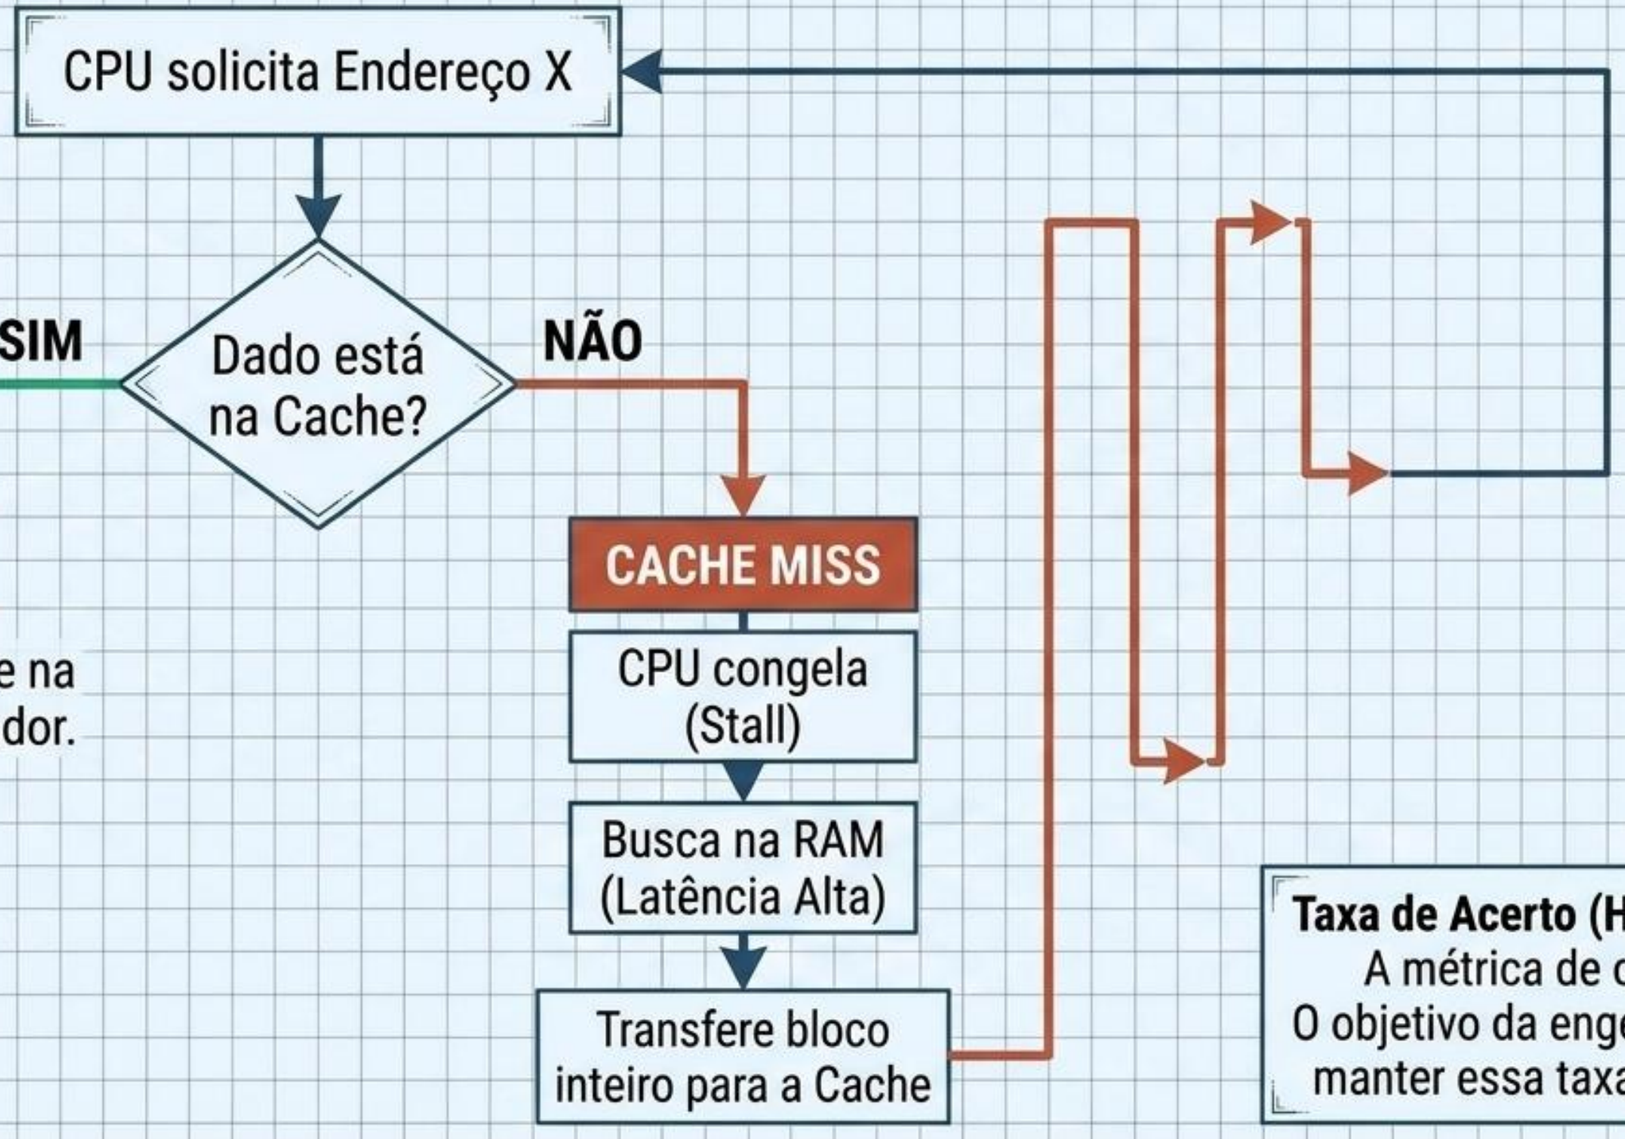
Temporal: Instruções de loop são repetidas rapidamente.

Espacial: Endereços contíguos do vetor são varridos em sequência.

A cache não adivinha o futuro, ela aposta na estatística de comportamento dos programas.

Gemini Notebook

O Caminho do Dado: Anatomia do Hit e Miss



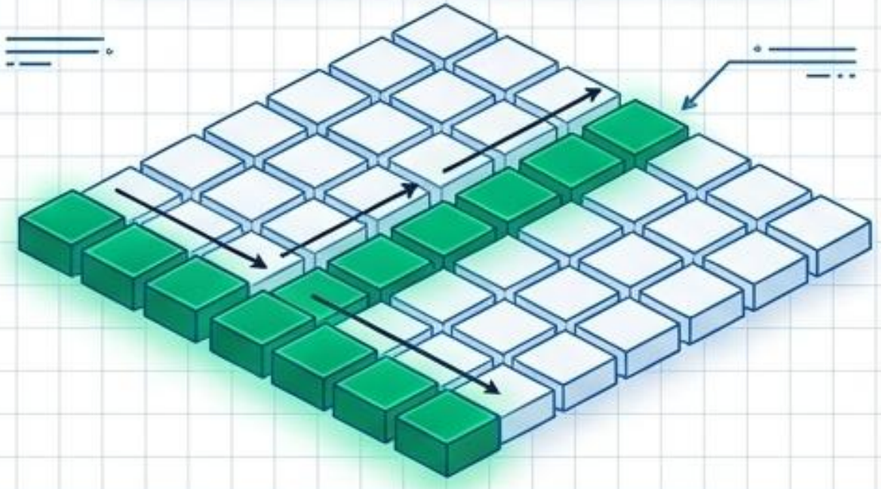
Taxa de Acerto (Hit Ratio):
A métrica de ouro.
O objetivo da engenharia é manter essa taxa > 95%.

Gemini Notebook

Código Consciente: O Padrão de Acesso Importa

Acesso por Linhas (Otimizado)

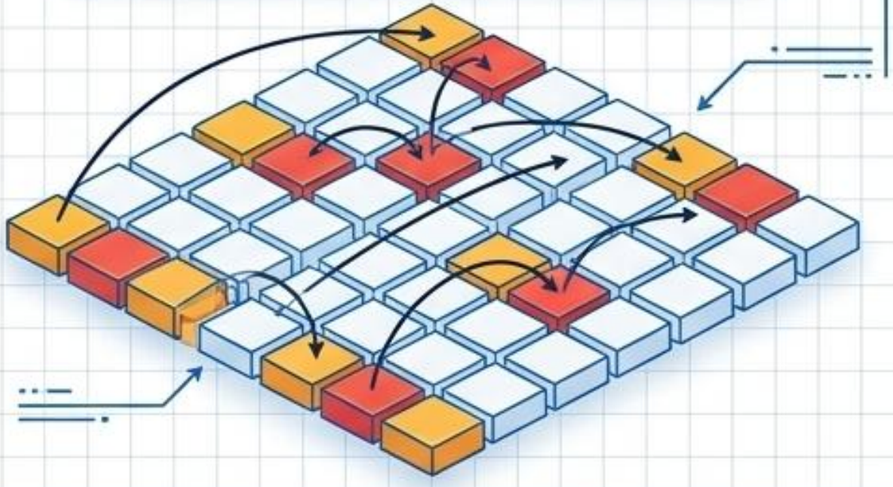
```
for (i = 0; i < N; i++) {
   for (j = 0; j < N; j++) {
      matriz[i][j] = 0;
   }
}
```



Aproveita blocos contíguos trazidos para a cache. Alta taxa de Cache Hit.

Acesso por Colunas (Gargalo)

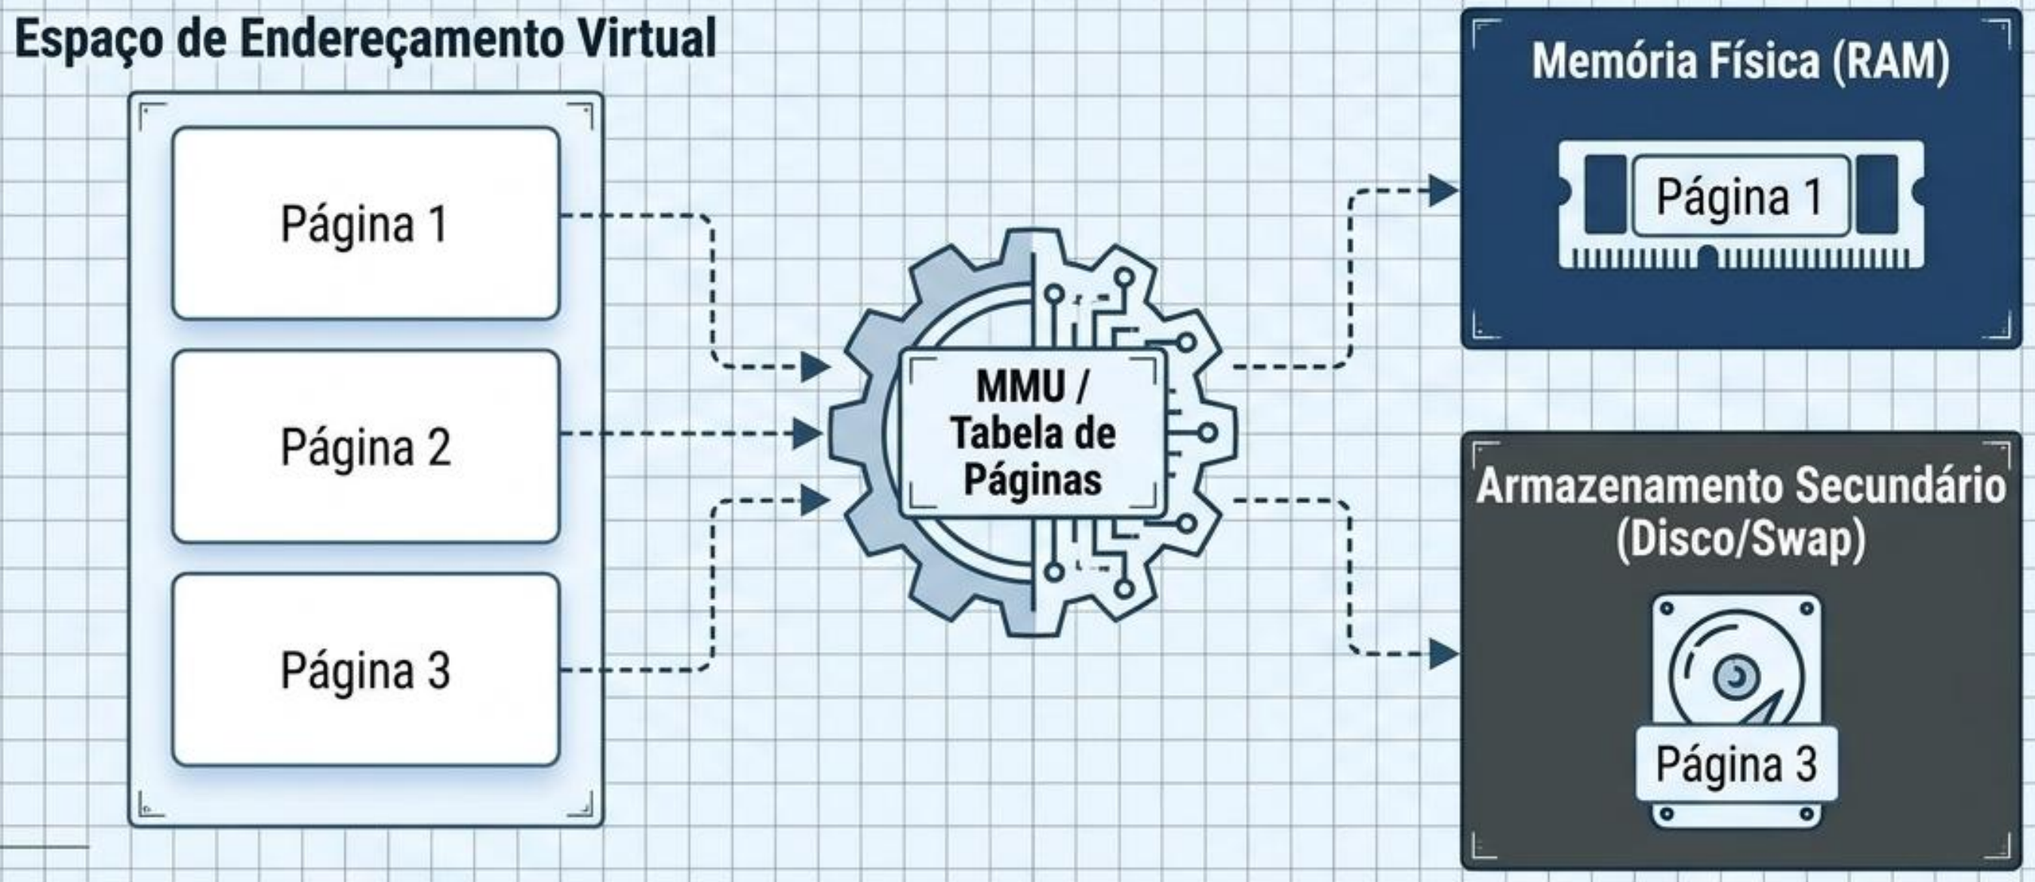
```
for (j = 0; j < N; j++) {
   for (i = 0; i < N; i++) {
      matriz[i][j] = 0;
   }
}
```



Gera saltos longos de endereço. Desperdiça a localidade espacial e causa Cache Misses massivos.

Gemini Notebook

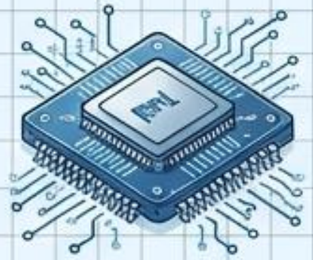
Expandindo Limites: Memória Virtual



- **A Ilusão:** O Sistema Operacional dá a cada programa a percepção de ter RAM infinita e exclusiva, dividida em Páginas.
- **O Custo:** Se a CPU pedir uma página que está no disco, ocorre um Page Fault (milhões de ciclos de atraso).

Gemini Notebook

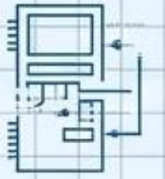
Batalha de Conceitos: Cache vs. Memória Virtual



MEMÓRIA CACHE



Objetivo principal: Acelerar o acesso à RAM.



Gerenciamento: Totalmente por Hardware (invisível ao SO).

Unidade de Transferência: Blocos / Linhas (Bytes).

O que o Hit proporciona? Velocidade térmica do processador.

MEMÓRIA VIRTUAL

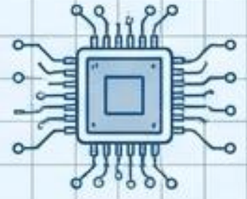
Objetivo principal: Aumentar a capacidade da RAM usando disco.

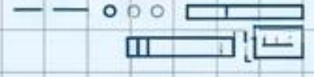


Gerenciamento: Sistema Operacional + Hardware (MMU).

Unidade de Transferência: Páginas (Kilobytes).

O que o Miss ocasiona? Page Fault (Falha catastrófica de latência).

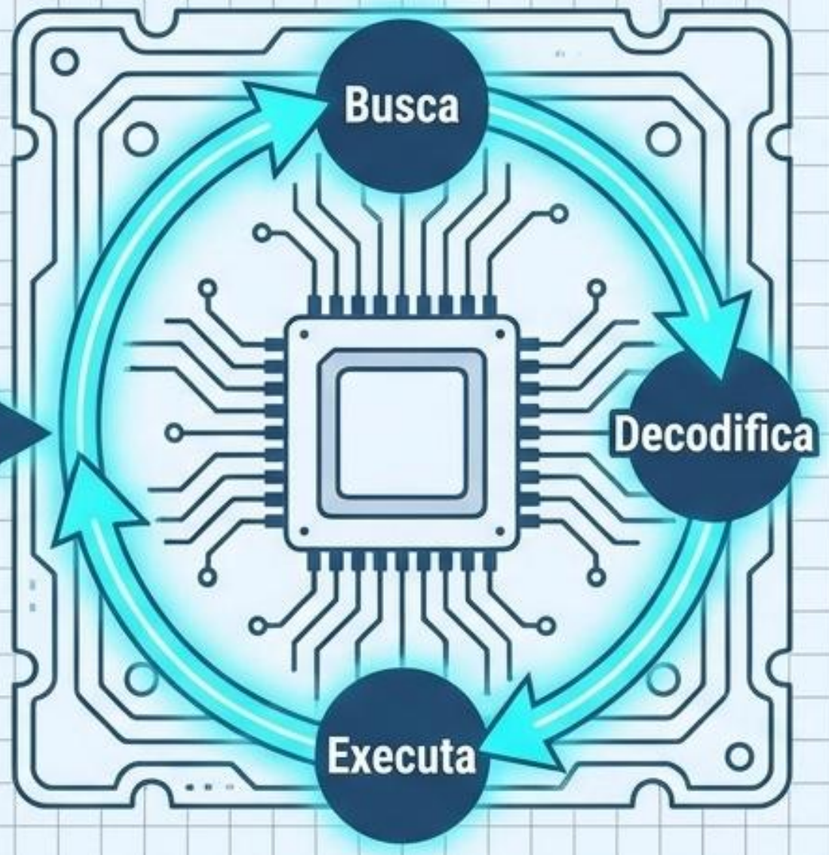




Mais RAM torna a CPU mais rápida?
Não. Apenas **evita os catastróficos** Page Faults.
Quem alimenta a CPU em alta velocidade é a Cache.

Gemini Notebook

Integrando as Peças: O Ciclo de Execução Retomado

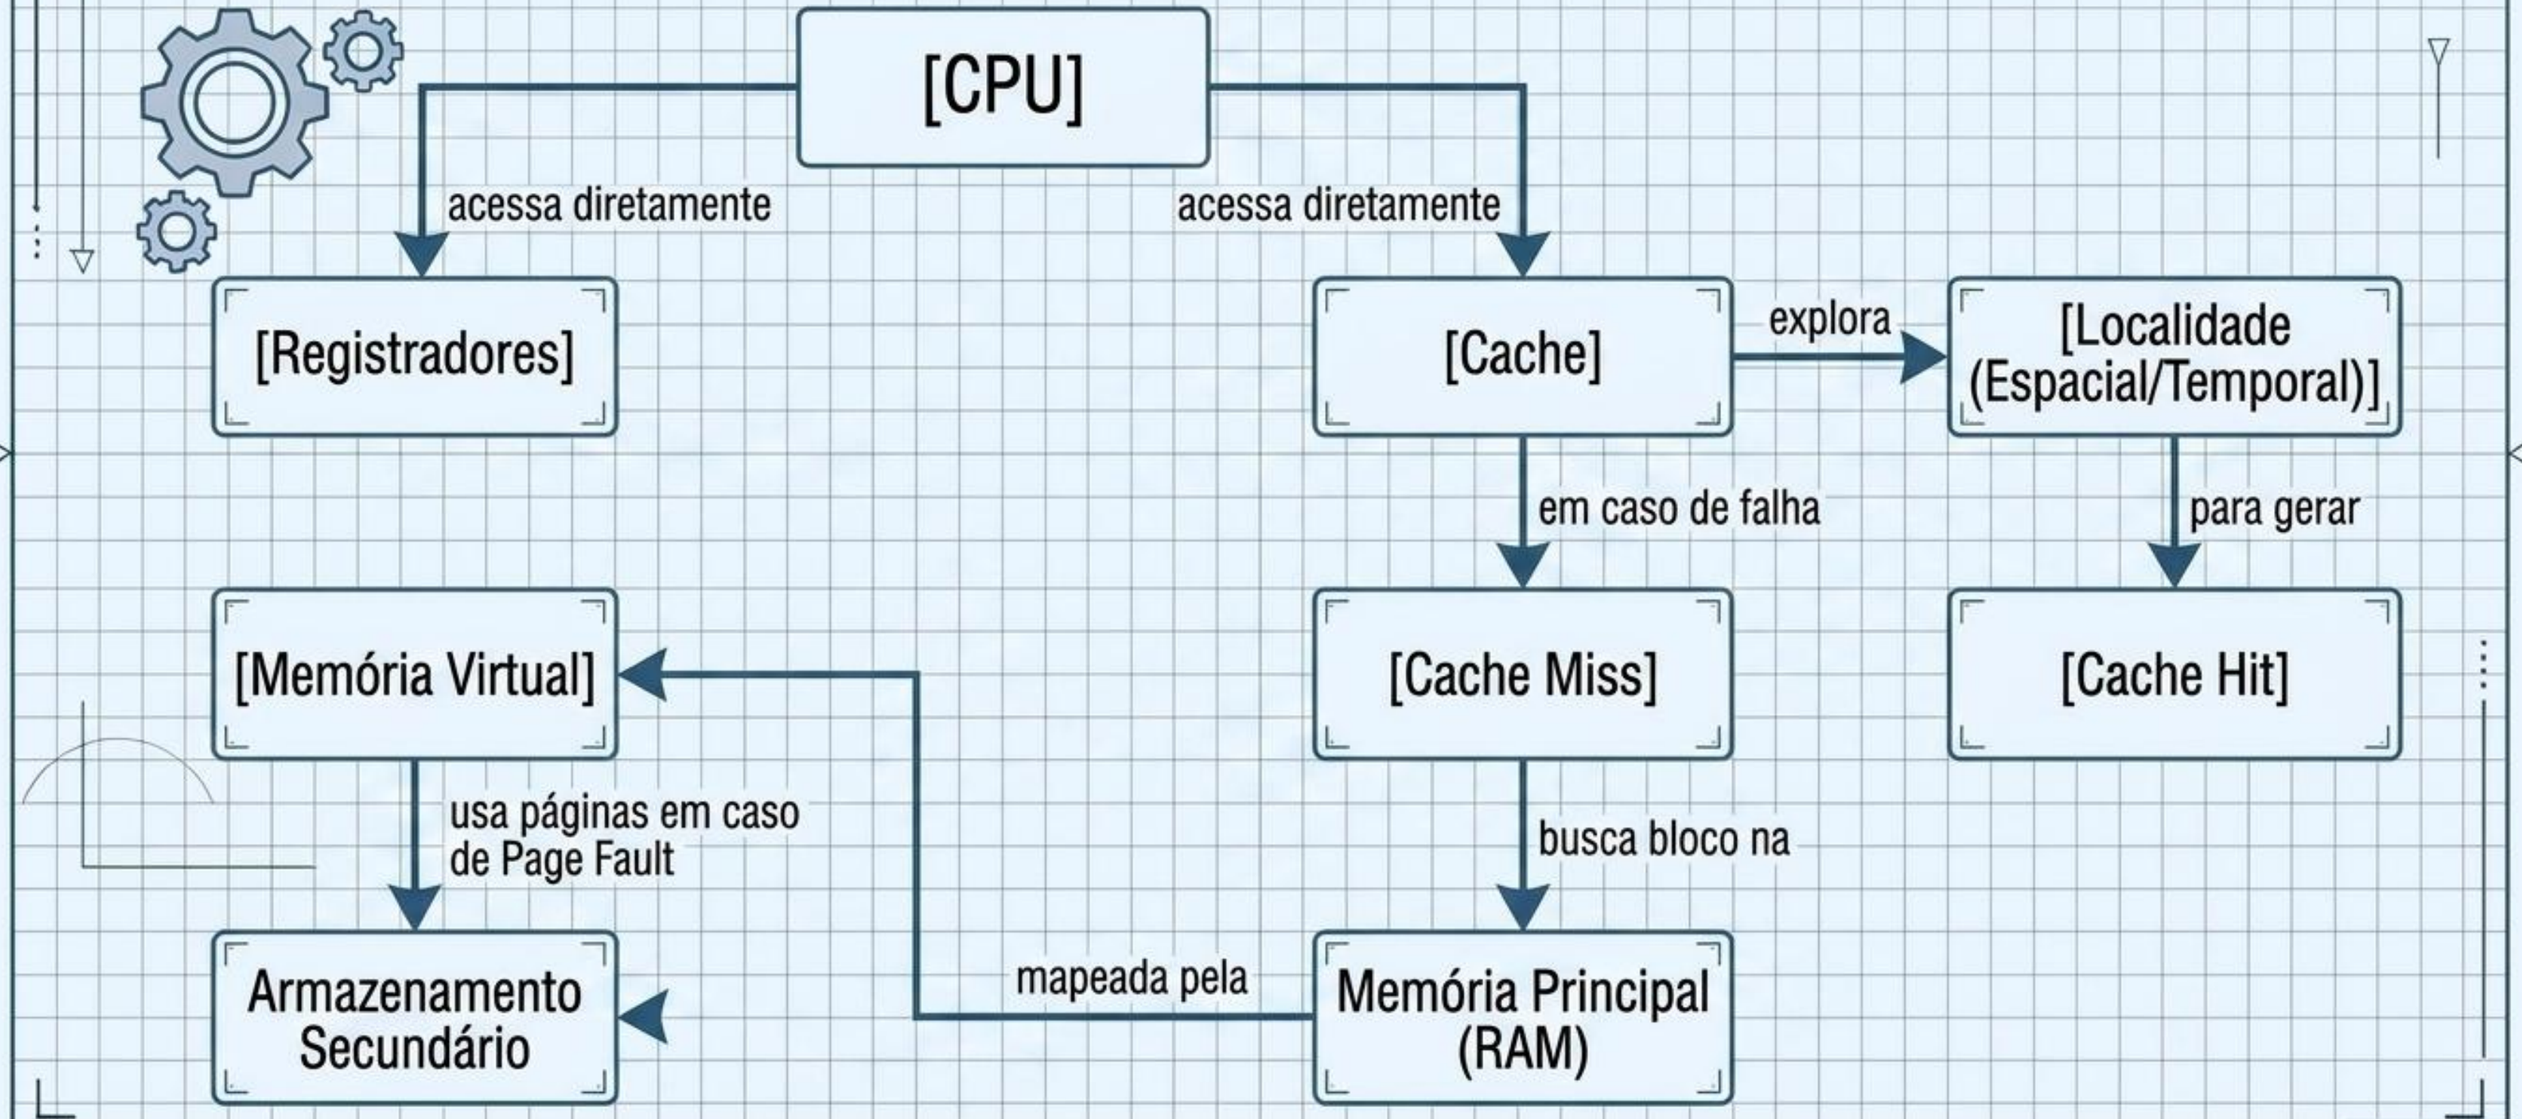


- A CPU é uma máquina faminta e cega para o mundo externo. Ela opera exclusivamente com o que está em seus registradores.
- Todo o sistema de memória trabalha nos bastidores para garantir que o registrador contenha o dado certo no ciclo de clock exato.

Registrador ← **Cache L1/L2/L3** ← **Memória RAM** ← **Disco Rígido**

Gemini Notebook

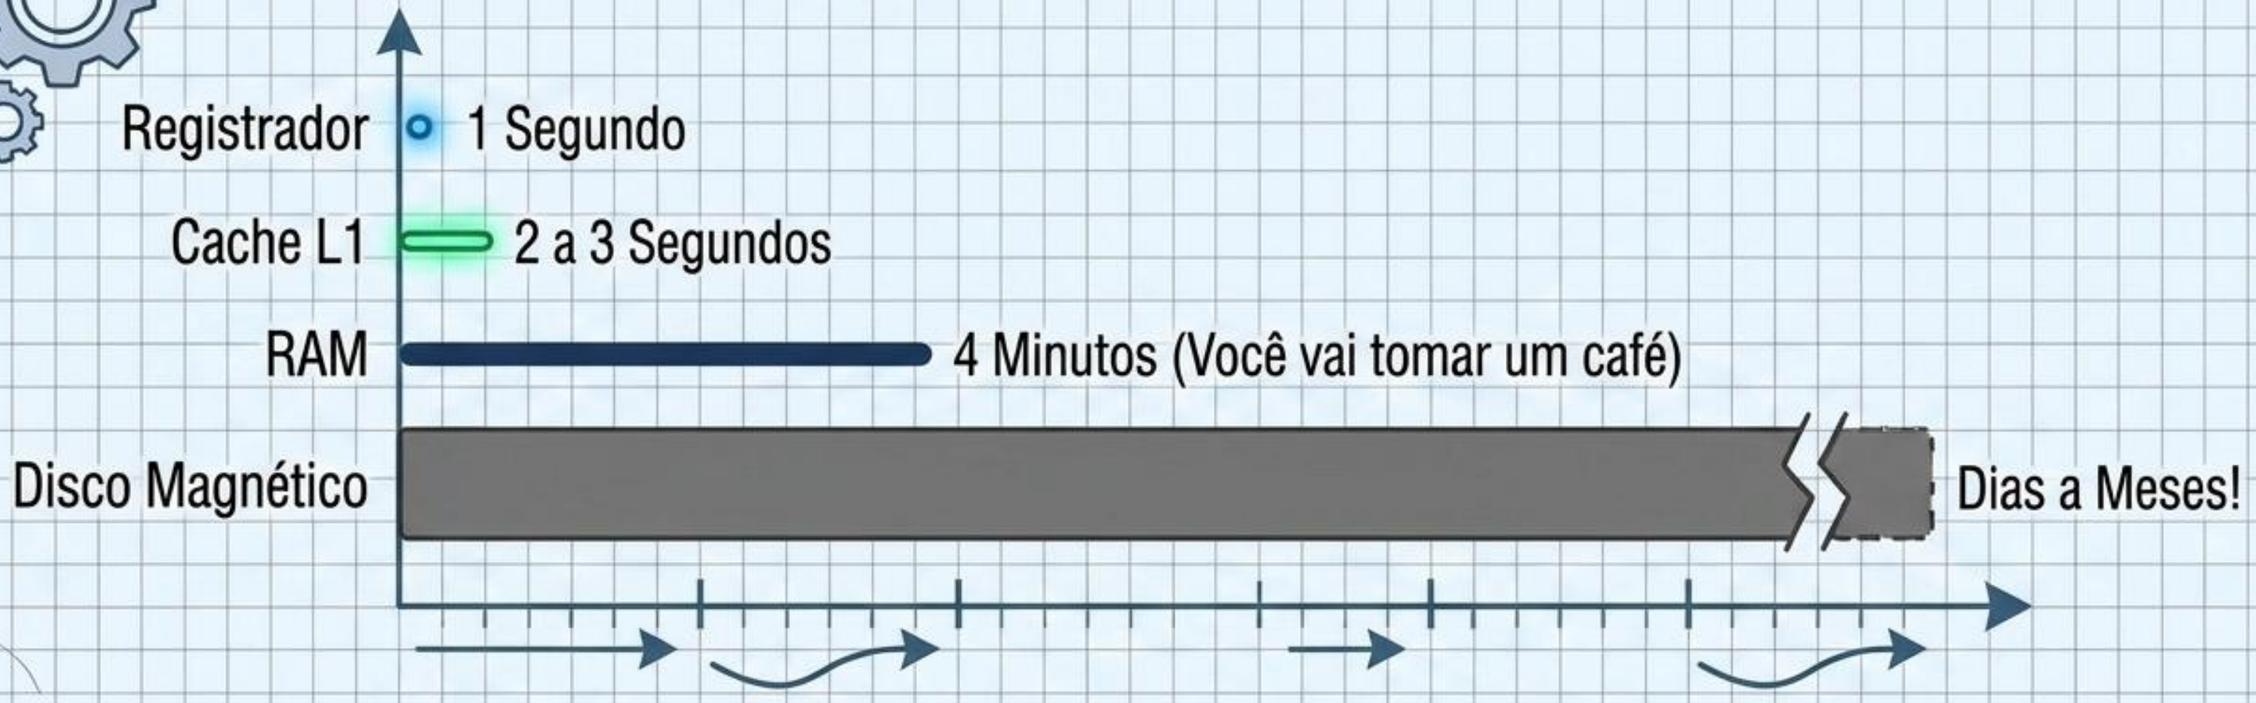
Mapa Conceitual da Unidade



Gemini Notebook

Trade-offs em Perspectiva: O Paradoxo do Tempo

Se 1 Ciclo de CPU (1 ns) equivalesse a 1 Segundo na vida real:



Conclusão: Otimizar um sistema não é apenas comprar um processador com clock maior; é evitar que ele espere 'meses' por um dado.

Gemini Notebook

O Que Devemos Levar Desta Unidade?

1. O Desempenho é um Ecossistema

Um computador veloz exige o equilíbrio perfeito entre a velocidade de processamento da CPU e a banda/latência do subsistema de memória.

2. A Ilusão é a Solução

A hierarquia de memória é uma obra-prima da engenharia que nos entrega a capacidade do disco rígido com a velocidade térmica dos registradores.

3. O Código Importa

Entender a localidade e o fluxo de dados transforma bons programadores em arquitetos de software de alto desempenho.

Próxima parada: Arquiteturas de Barramentos e I/O.

Gemini Notebook