Arquiteturas Paralelas e Não Convencionais

Da Execução Sequencial ao Processamento Massivo

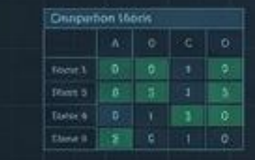
UNEMAT

Prof. Me. Juvenal Silva Neto

Disciplina: Arquitetura e Organização de Computadores

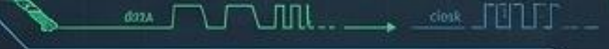
Curso: Bacharelado em Ciência da Computação

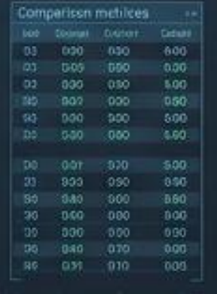
Universidade do Estado de Mato Grosso — UNEMAT

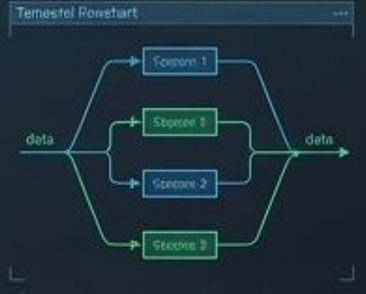


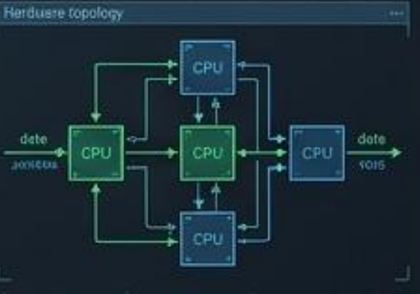










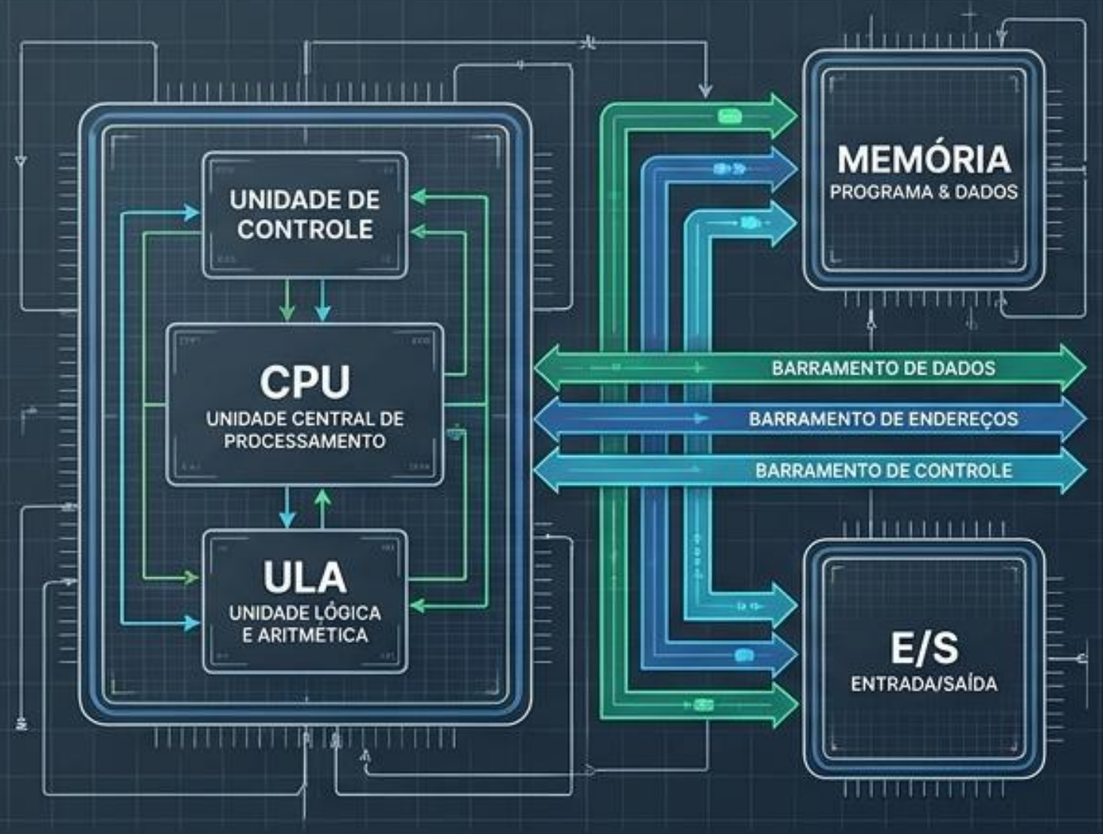


Gemini Notebook

O Ponto de Partida: A Máquina Sequencial

Como a execução de uma instrução por vez dominou as primeiras décadas da computação?

ARQUITETURA VON NEUMANN



O Paradigma Original: 1 instrução → 1 dado → 1 processador.

CICLO DE INSTRUÇÃO CLÁSSICO

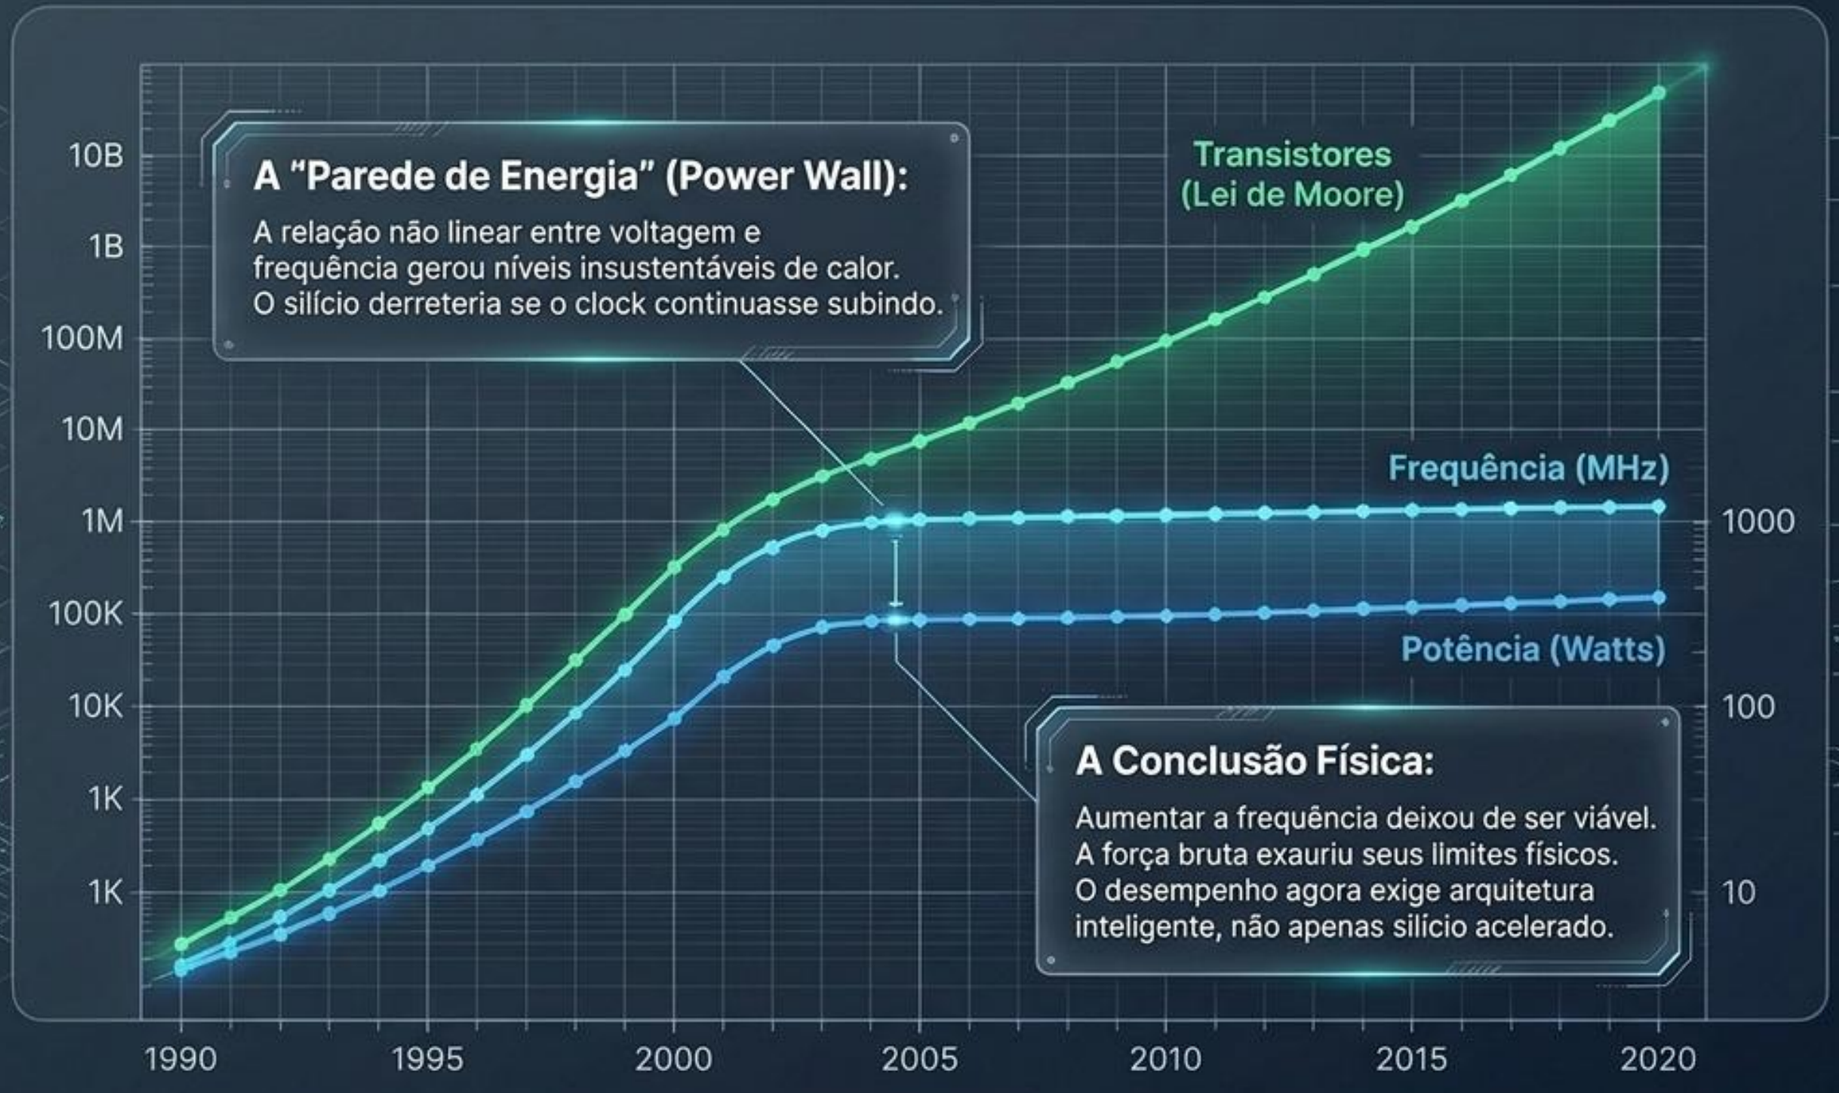


A Evolução Linear: O ciclo clássico dependia de um fluxo perfeitamente sequencial armazenado na memória. O gargalo histórico sempre foi a velocidade de busca e a execução passo a passo.

Gemini Notebook

O Fim de uma Era: Por que o Clock Estagnou?





A "Parede de Energia" (Power Wall):

A relação não linear entre voltagem e frequência gerou níveis insustentáveis de calor. O silício derreteria se o clock continuasse subindo.

A Conclusão Física:

Aumentar a frequência deixou de ser viável. A força bruta exauriu seus limites físicos. O desempenho agora exige arquitetura inteligente, não apenas silício acelerado.



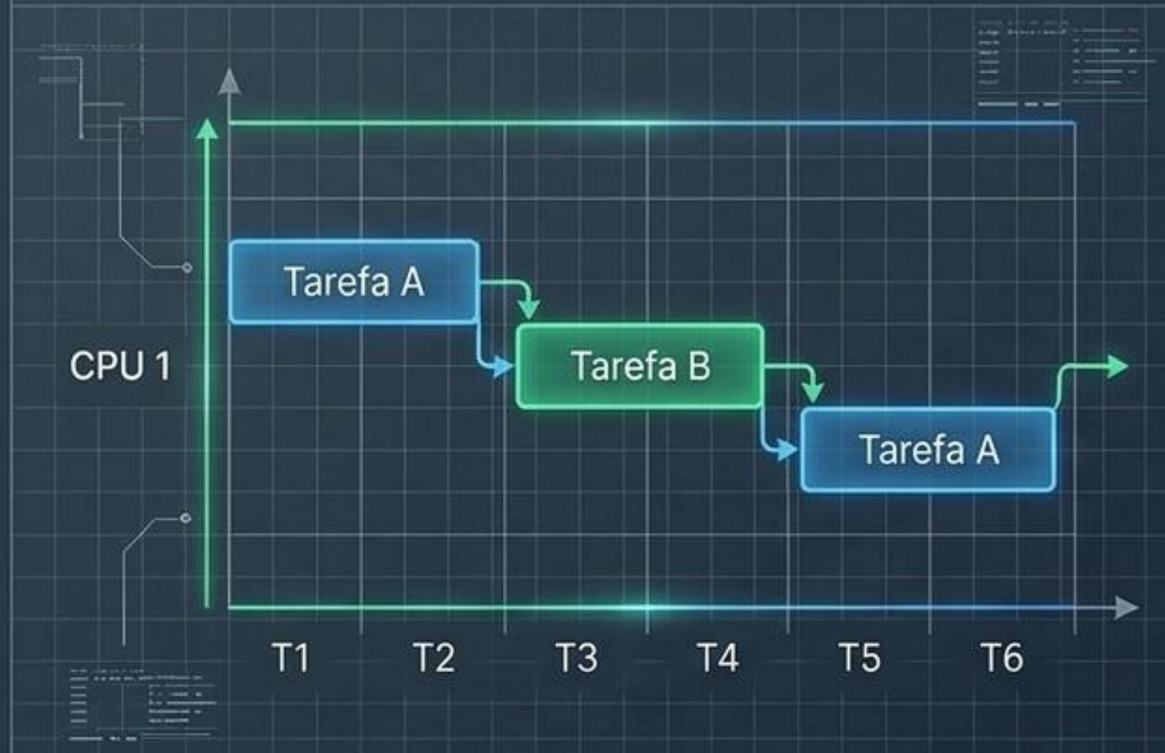
ID23.2.101.19845

Gemini Notebook

Alinhamento de Conceitos: Concorrência vs. Paralelismo

Concorrência

Ilusão de simultaneidade (Gerenciada pelo Sistema Operacional)



Paralelismo

Execução física simultânea (Hardware)

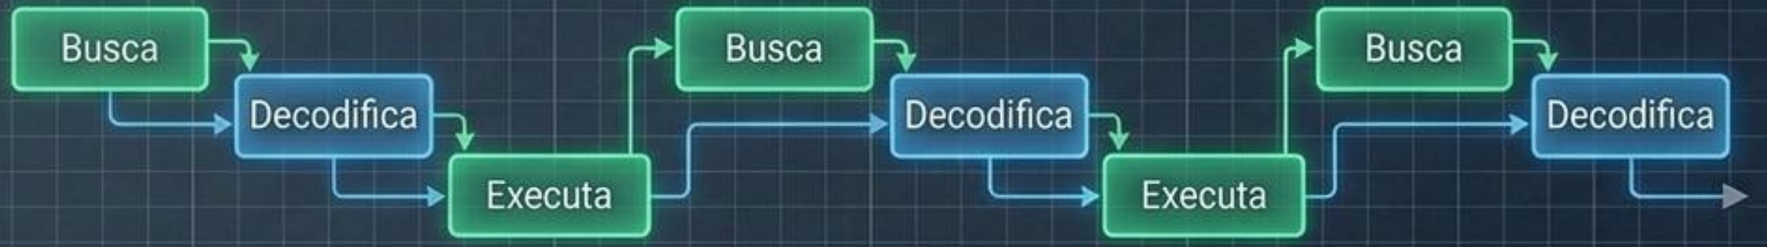


A **concorrência** lida com o gerenciamento de várias tarefas; o **paralelismo** ataca a execução física e simultânea dessas tarefas.

Gemini Notebook

A Engenharia Interna: Paralelismo em Nível de Instrução (ILP)

Pipeline Básico



Despacho Dinâmico: O hardware extrai paralelismo de códigos sequenciais executando mais de uma instrução por ciclo de clock.

Superescalar



O **Limite do ILP**: Esbarra nas dependências verdadeiras de dados (RAW, WAW) e conflitos de recursos.

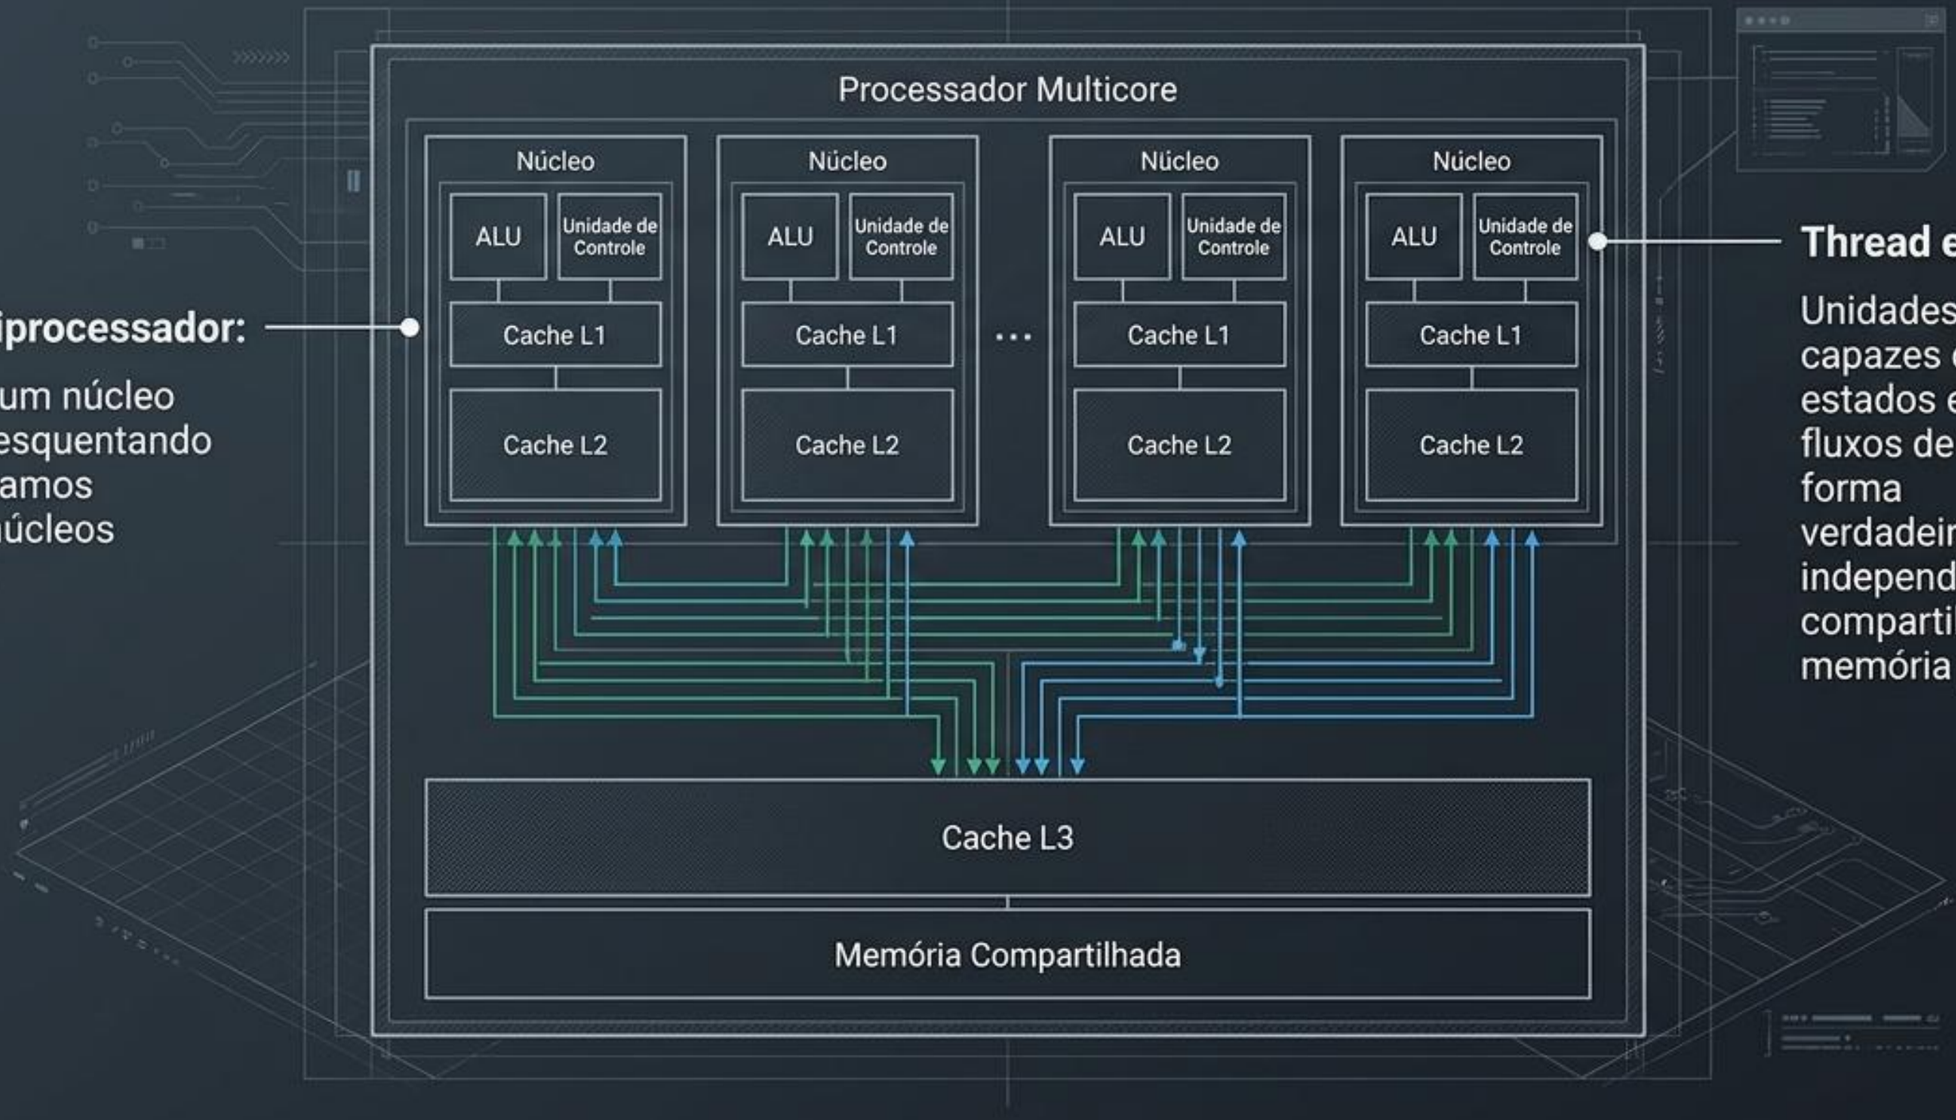
Gemini Notebook

A Resposta da Indústria: Processadores Multicore

Mais núcleos significam automaticamente mais velocidade?

Chip Multiprocessador:

Em vez de um núcleo complexo esquentando demais, usamos múltiplos núcleos eficientes.



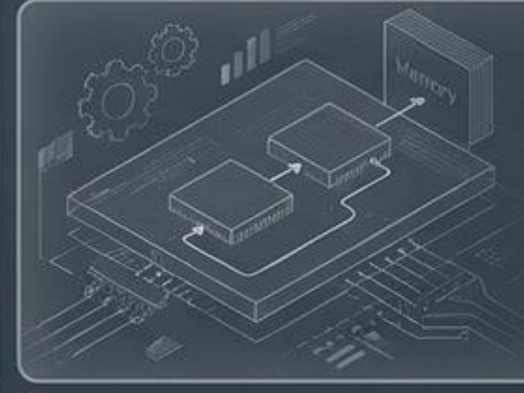
Thread em Hardware:

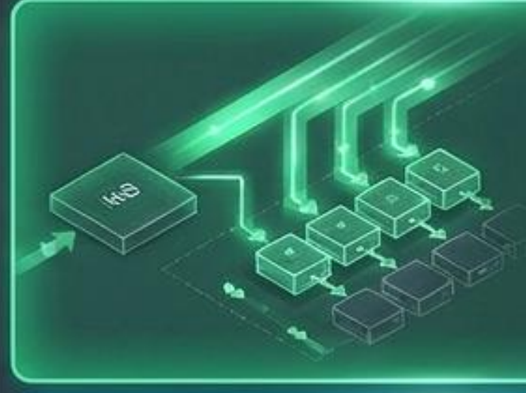
Unidades físicas capazes de manter estados e executar fluxos de instruções de forma verdadeiramente independente, compartilhando a memória principal.

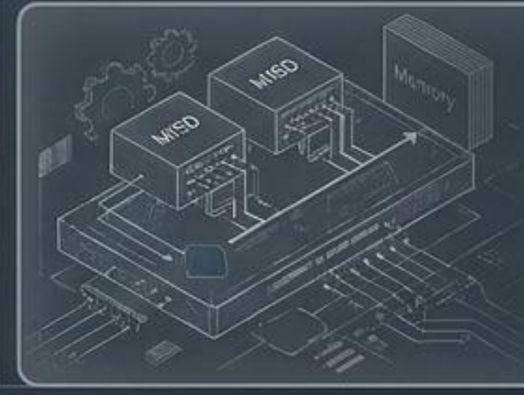
Gemini Notebook

O Padrão Ouro da Classificação: Taxonomia de Flynn

Fluxo de Instruções \ Fluxo de Dados	Único	Múltiplo
Único	**SISD** A máquina sequencial clássica (PC antigo).	**SIMD** Processamento vetorial e GPUs (Gráficos, Matrizes).
Múltiplo	**MISD** Aplicações restritas (Sistemas tolerantes a falhas).	**MIMD** Multicore e Clusters (Servidores, Computadores modernos).









A evolução migrou do SISD clássico em duas frentes: MIMD para propósito geral e SIMD para aceleração de cálculos paralelos massivos.

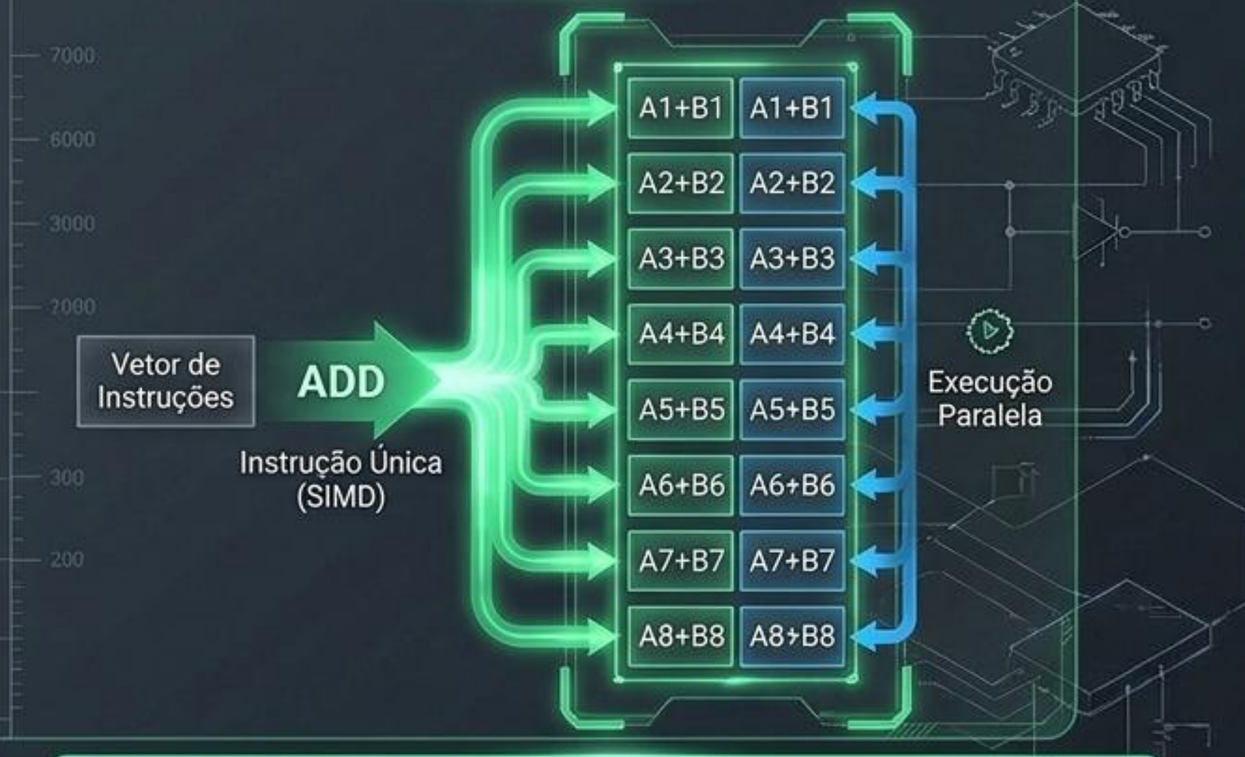
Gemini Notebook

SIMD: Uma Única Ordem, Milhares de Ações

Execução Escalar (SISD)



Processamento Vetorial (SIMD)



A Essência do SIMD:
Essencial para extensões multimídia (SSE/AVX).

Por que importa?
Aplicações que transformam grandes volumes de dados de forma uniforme (manipulação de pixels em imagens, processamento de áudio, operações matemáticas em matrizes).

A Essência do SIMD:
Essencial para extensões multimídia (SSE/AVX).

Por que importa?
Aplicações que transformam grandes volumes de dados de forma uniforme (manipulação de pixels em imagens, processamento de áudio, operações matemáticas em matrizes).

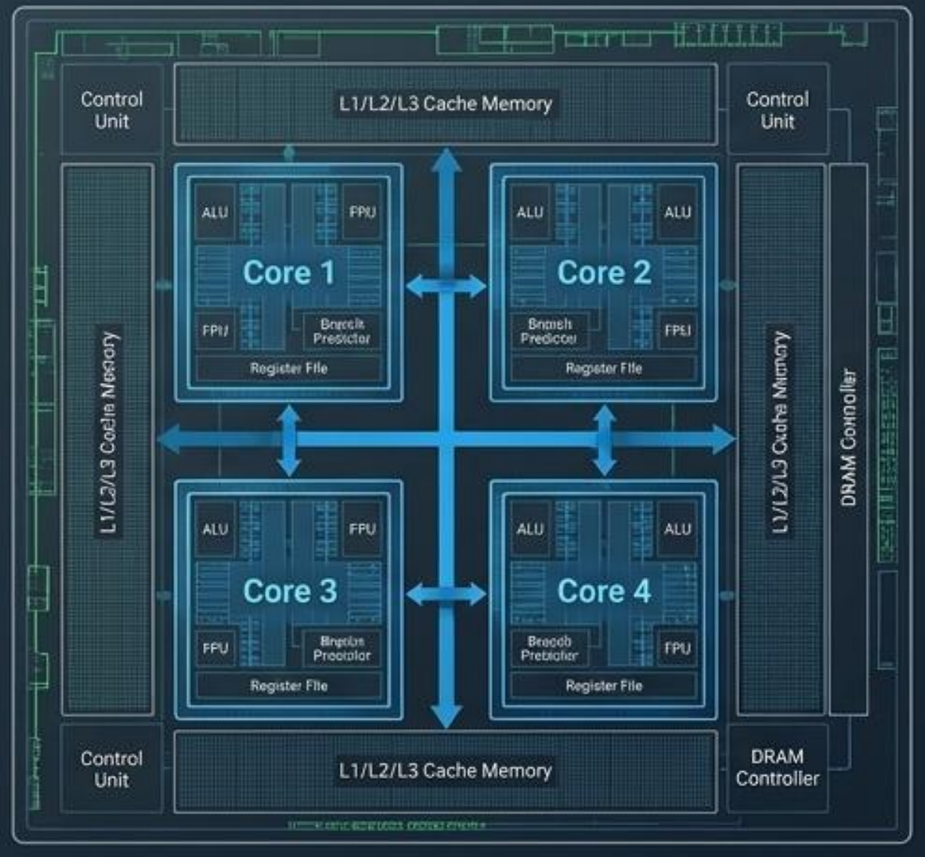
Gemini Notebook

A Anatomia do Paralelismo Massivo: GPUs

Por que GPUs são tão eficientes em processamento de imagens e IA?

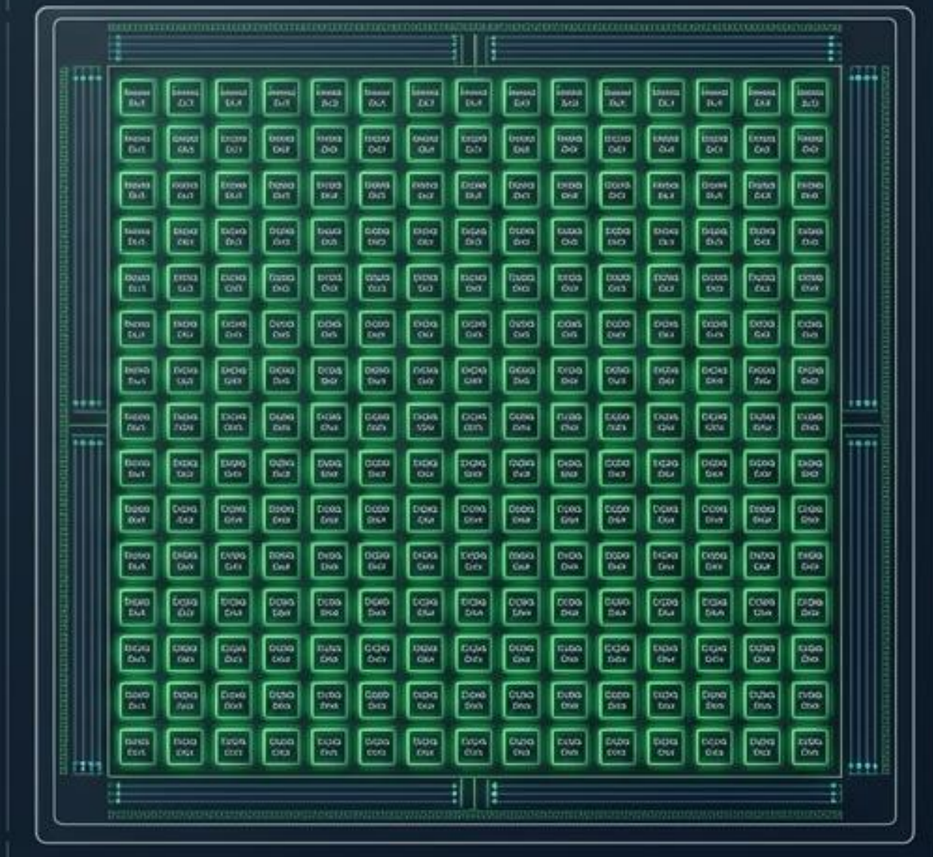
Painel CPU (Paralelismo de Tarefas)

Otimizado para baixa latência e controle complexo.



Painel GPU (Paralelismo de Dados)

Otimizado para throughput (taxa de transferência extrema).



A GPU não é 'melhor'; ela sacrifica a lógica de desvio condicional e memória cache sofisticada em troca de milhares de unidades matemáticas executando o mesmo cálculo simultaneamente.

Gemini Notebook

Colaboração em Larga Escala: Sistemas Multiprocessadores

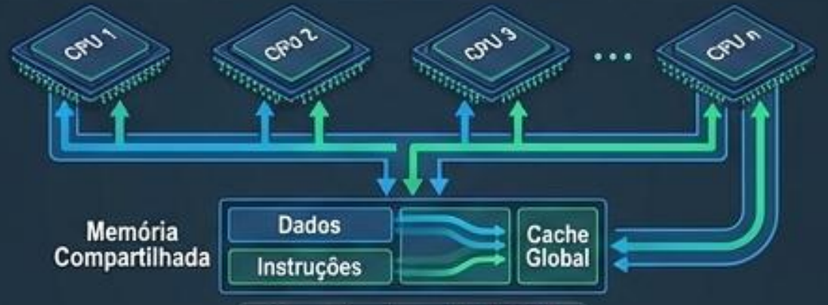
Multicore
(On-chip)



Coupling Level: TIGHTEST

Núcleos dentro do mesmo silício.

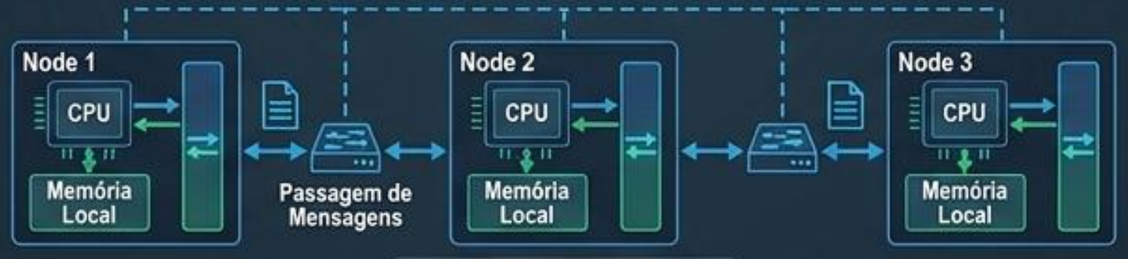
Multiprocessamento
(SMP)



Coupling Level: TIGHT

Forte Acoplamento
Vários chips processadores em uma placa-mãe, todos ligados por um barramento fisico à mesma Memória Compartilhada.

Clusters
(Processamento Distribuído)



Coupling Level: LOOSE

Fraco Acoplamento
Computadores independentes conectados por rede, cada um com sua própria memória, utilizando passagem de mensagens.

O Desafio
Sincronizar processadores e evitar o overhead de comunicação e a contenção no barramento de memória.

Gemini Notebook

O Cenário Atual: Arquiteturas Heterogêneas (SoC)

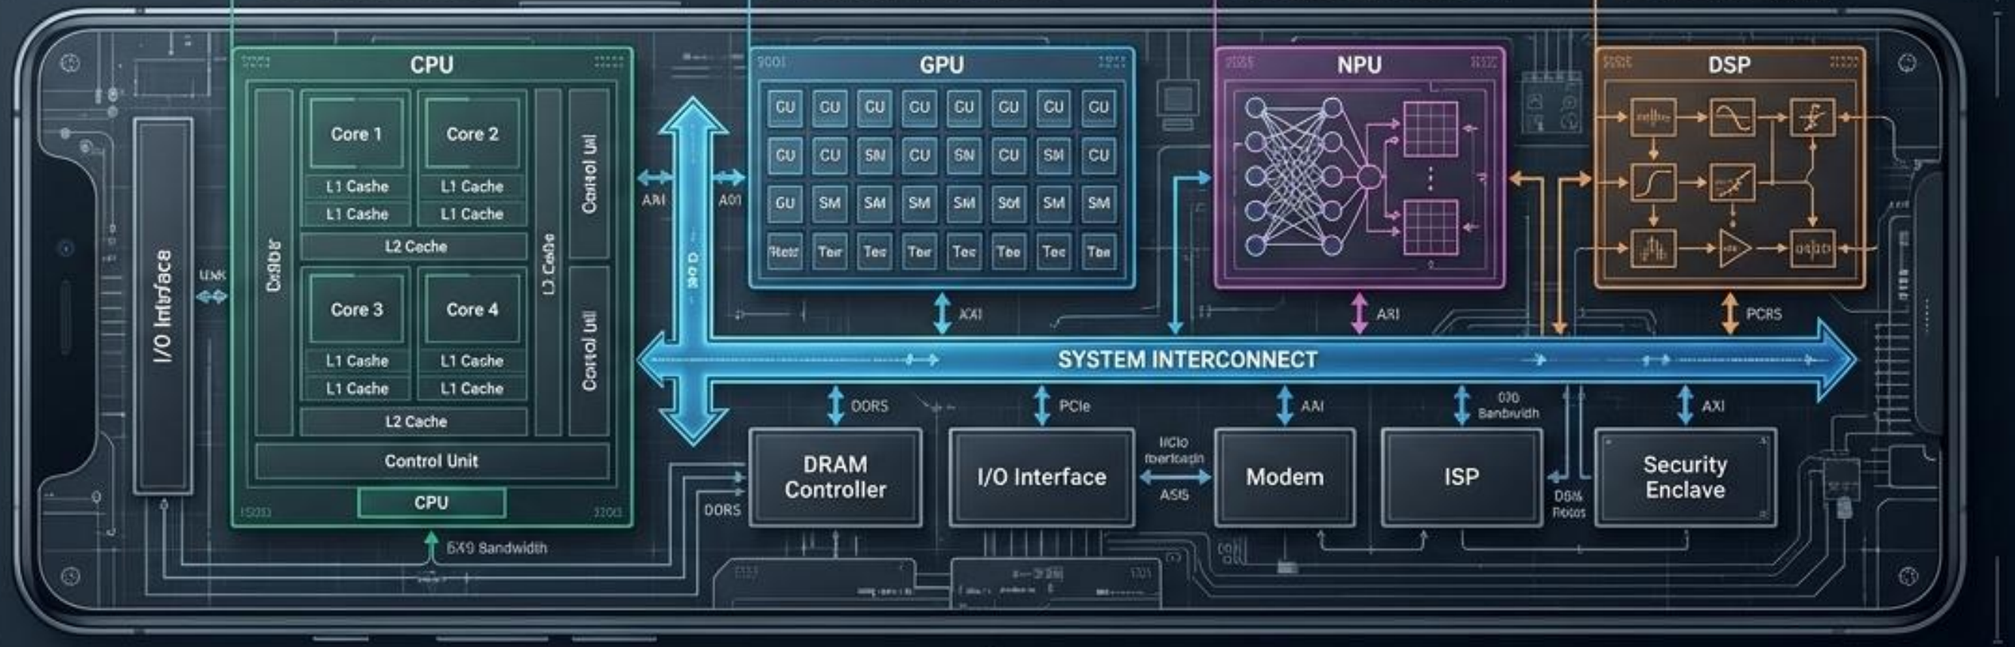
Por que combinar CPU e GPU no mesmo sistema?

CPU O maestro executando o SO.

GPU Renderização e matemática intensiva.

NPU Acelerador de Inteligência Artificial.

DSP Processamento de sinal/imagem.



Integração e Eficiência

O abandono da abordagem "tamanho único". O sistema delega dinamicamente trabalhos específicos para aceleradores especializados, otimizando drasticamente a eficiência energética.

Gemini Notebook

Fronteiras: Arquiteturas Não Convencionais



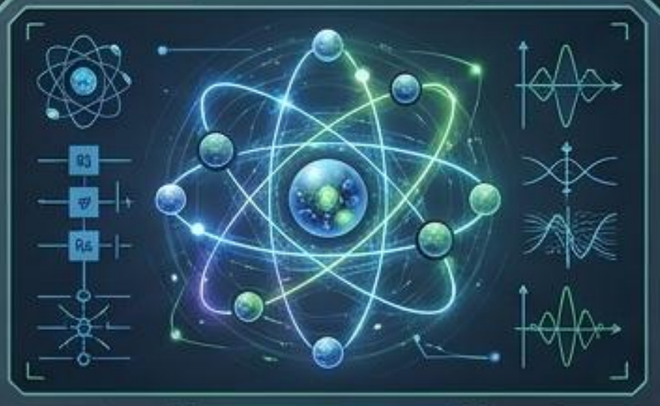
Computação Neuromórfica

Imita a estrutura de picos dos neurônios. Extremamente eficiente em energia; ideal para sensores edge e inferência em IA.



Processamento Próximo à Memória (PIM)

Move as ALUs para dentro da matriz de memória. Elimina o gargalo de mover dados pelo barramento, economizando tempo e energia.



Computação Quântica

Abordagem experimental baseada em superposição de estados (Qubits). Muda radicalmente a solução de problemas complexos de otimização.

Gemini Notebook

O Choque de Realidade: A Lei de Amdahl

Distribuição de Tempo da Tarefa (10s)



Gráfico de Speedup Assintótico



STRUCTURA

O Imposto Sequencial:

Se aplicarmos infinitos processadores na parte paralela, o tempo dela cai para zero. Porém, a parte sequencial (5s) permanece inalterada.



STRUCTURA

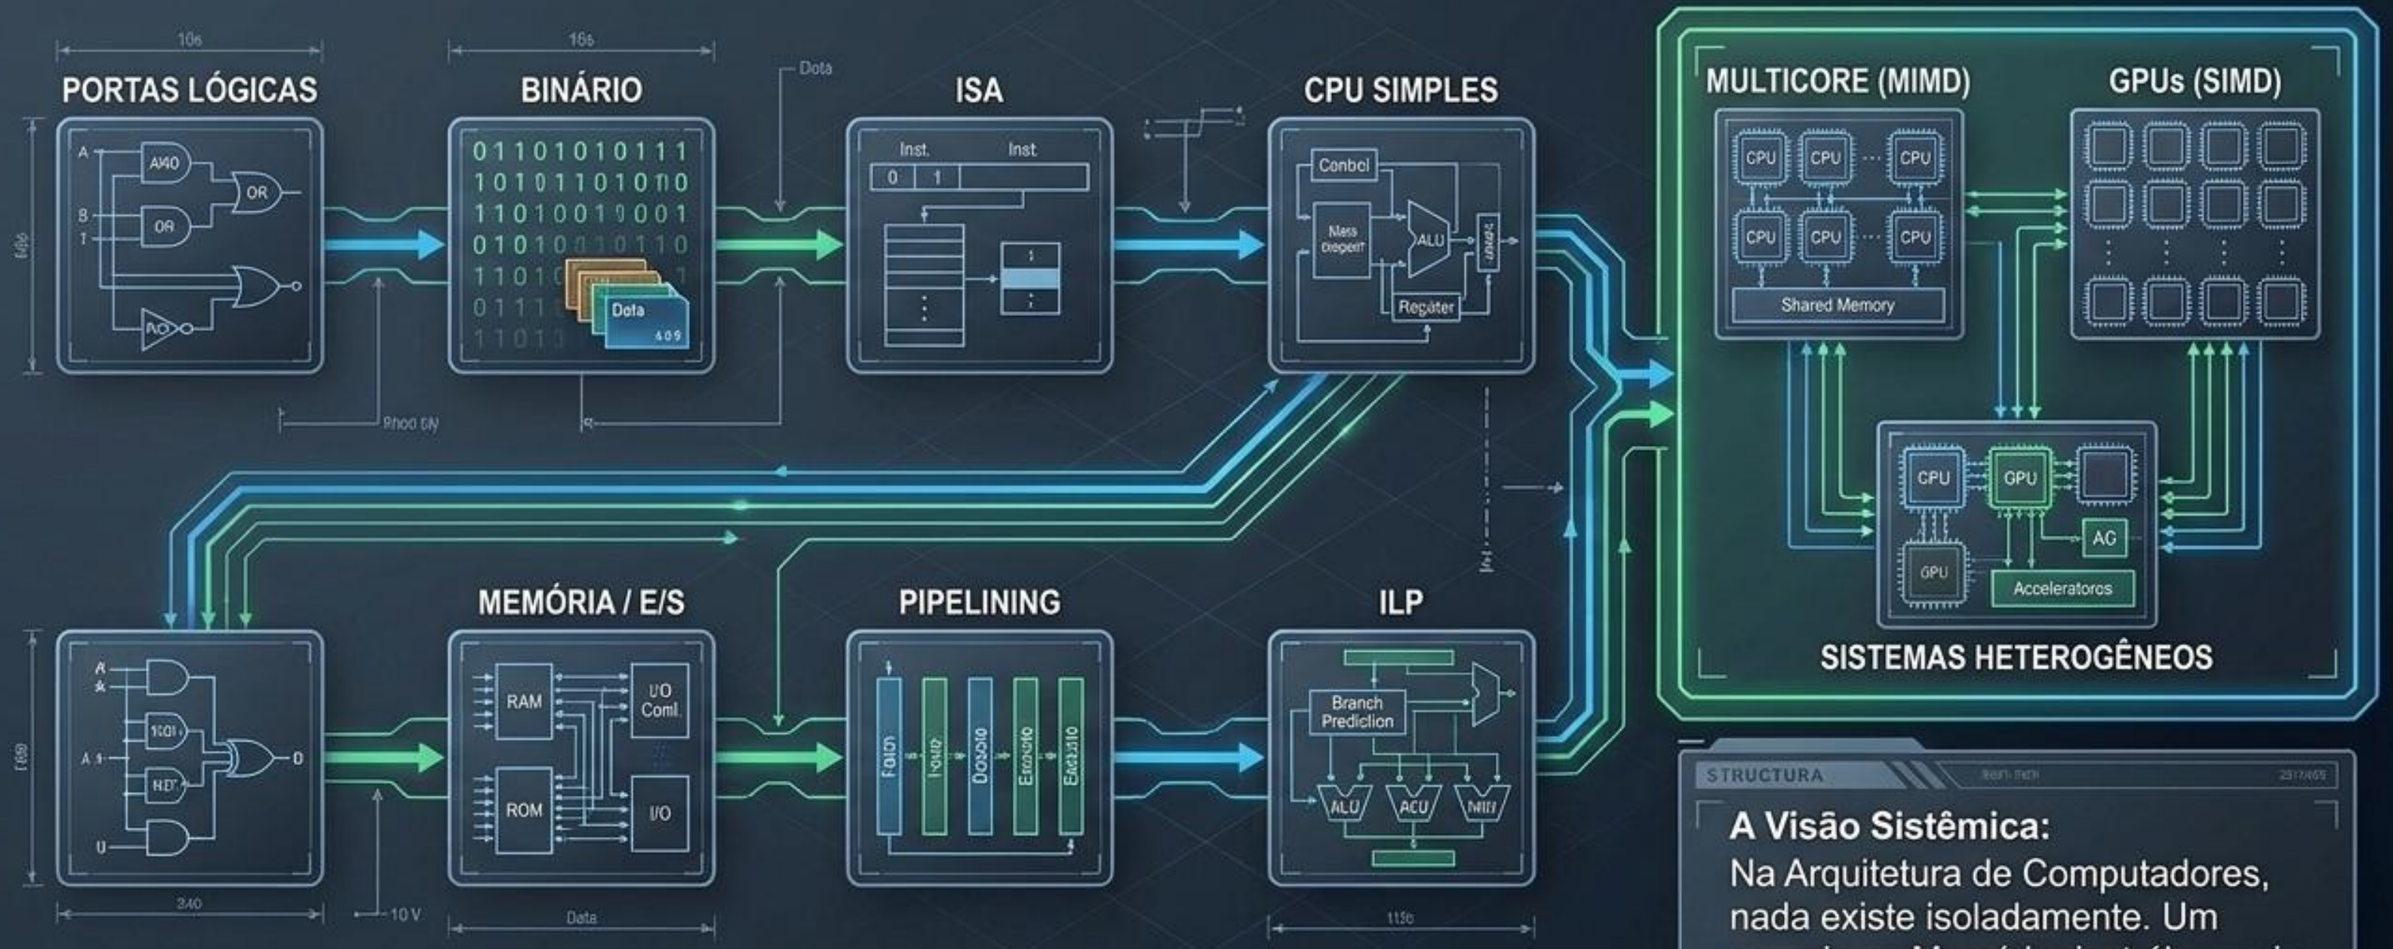
Conclusão Matemática:

O ganho máximo absoluto de velocidade (Speedup) é de 2x, não importa se você usar 2 ou 2 milhões de núcleos. Há sempre um limite imposto pelo overhead e pela porção sequencial.

$$\text{Speedup} = \frac{1}{(1-P) + \frac{P}{N}}$$ onde P = Fração Paralela (0.5) e N = Número de Processadores

Gemini Notebook

INTEGRAÇÃO DA DISCIPLINA: VISÃO SISTÊMICA



STRUCTURA

A Visão Sistêmica:
Na Arquitetura de Computadores, nada existe isoladamente. Um gargalo na Memória destrói o ganho de um Pipeline, que destrói o ganho de um Multicore.

Gemini Notebook



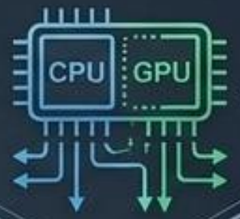
Barreira Térmica

A execução sequencial parou. A física da dissipação térmica forçou a engenharia a abandonar o aumento bruto de clock.



Escalas de Paralelismo

O hardware ataca a lentidão em múltiplas frentes simultâneas: Nível de Instrução, Núcleos (Multicore) e Dados (SIMD).



Especialização Heterogênea

CPUs (Baixa Latência) e GPUs (Alto Throughput) convergem em SoCs integrados.



Os Limites da Matemática

A Lei de Amdahl governa o universo paralelo.
O verdadeiro desempenho é limitado pela lógica sequencial e pelo overhead.

Universidade do Estado de Mato Grosso — UNEMAT | Sessão Aberta para Perguntas

Gemini Notebook